OST
Ostschweizer
Fachhochschule

# Topological Data Analysis for Crypto Mean-Reversion Trading

## Mithilfe topologischer Datenanalyse korrelierende Crypto-Assets ausfindig machen

Bachelorarbeit

Amato Ilija
Mikus Ryan

**Referent:** Dr. Shao Jü Woo
**Koreferent:** Prof. Dr. Daniel Lenz

21. August 2026

# Abstract

Pair-Trading setzt voraus, dass geeignete, tatsächlich korrelierende Assets bestimmt werden. Gängige Methoden dafür sind Berechnungen auf historischen Kursdaten oder Assets, deren Wertentwicklung auf denselben oder verwandten zugrunde liegenden Faktoren beruht. Der sich laufend ändernden Marktstruktur von Kryptowährungen wird das jedoch nicht gerecht.

Die vorliegende Arbeit untersucht, ob Topological Data Analysis (TDA) sich eignet, um solche Baskets systematisch und datengetrieben zu bestimmen. Dazu werden Kryptowährungen anhand ihres rollierenden Handelsvolumens in vier Liquiditäts-Baskets eingeteilt. Innerhalb jedes Baskets wird aus den paarweisen Korrelationsdistanzen der Asset-Returns mittels Single-Linkage-Clustering ein Dendrogramm konstruiert, welches mathematisch äquivalent zur nulldimensionalen persistenten Homologie (H0) einer Vietoris-Rips-Filtration ist. Aus diesem Dendrogramm wird pro Zeitfenster der Cluster mit der grössten Persistenz extrahiert und als handelbare Cluster verwendet. Innerhalb eines Clusters werden Asset-Paare auf Kointegration und Mean-Reversion geprüft und mittels einer Bollinger-Band/Z-Score-Strategie auf dem Preis-Level-Spread gehandelt, ergänzt um volatilitätsabhängige Schwellenanpassung, symmetrischen Ausstieg und dynamische Positionsgrössenbestimmung. Einige Strategie-Hyperparameter werden mittels des Optuna-Frameworks über mehrere nicht überlappende Zeitfenster kalibriert. Die Grundlage bilden 5-Minuten-OHLCV-Daten von Binance. 47 Kryptowährungen im Zeitraum vom 23.07.2024 bis 22.07.2026 (730 Tage).

Ohne Berücksichtigung von Transaktionskosten und Slippage erzielt die Strategie in Basket 1 und weiten Teilen von Basket 2 positive risikoadjustierte Renditen (Sharpe Ratio bis 2.6, Win Rate bis $70\,\%$), während Basket 3 durchgehend negativ bleibt. Unter realistischen Kosten (Handelsgebühr $10$ Basispunkte, Slippage $2$ Basispunkte) ist dies jedoch nicht der Fall: Keine der 14 untersuchten Basket/Kerzenlängen-Kombinationen erzielt eine positive risikoadjustierte Rendite (Sharpe Ratio zwischen $-2.9$ und $-12.5$, maximaler Drawdown bis $-11.5\,\%$).

Die TDA-basierte Clusterbildung identifiziert damit grundsätzlich Assetgruppen mit nachweisbarem Mean-Reversion-Verhalten und liefert gegenüber einer statischen, manuellen Paarwahl einen strukturellen Mehrwert. Die resultierende Handelsfrequenz erweist sich jedoch als unvereinbar mit der Kostenstruktur eines Kleinanleger-Marktzugangs. Für institutionelle Marktteilnehmer mit entsprechend tieferen Transaktionskosten könnte die Strategie hingegen wirtschaftlich tragfähig sein.

# Danksagung

Wir haben unseren Bachelor an der Ostschweizer Fachhochschule (OST) mit diesem Projekt abgeschlossen. Dieses Projekt wäre ohne die Betreuung von Shao Jü Woo nicht zustande gekommen. Mit seinem Fachwissen und seiner Erfahrung leitete er uns auf den richtigen Weg, wenn wir wieder vor einem Problem standen. Zu Beginn mussten wir uns das Fachwissen aneignen, und er hat uns nicht nur Material bereitgestellt, sondern uns auch geholfen, die quantitativen Methoden zu verstehen. Wir bedanken uns für seinen Einsatz und seine Unterstützung.

Ebenfalls möchten wir uns bei unserem Koreferenten, Prof. Dr. Daniel Lenz, für seine Inputs beim Fachmodul bedanken. Die Inputs halfen dabei, das Projekt präziser zu definieren.

Zuletzt möchten wir uns bei der Fachhochschule bedanken, die uns die Möglichkeit gegeben hat, den Bachelor und die Bachelorarbeit abzuschliessen.

# Inhaltsverzeichnis


**1 Einleitung** **1**
- 1.1 Aufgabenstellung . . . 1
- 1.2 Abgrenzung . . . 1

**2 Theoretische Grundlagen** **3**
- 2.1 Topologische Datenanalyse . . . 3
  - 2.1.1 Topologie und Homologie . . . 3
  - 2.1.2 Filtration und persistente Homologie . . . 4
- 2.2 Pair-Trading als mean-revertierende Handelsstrategie . . . 6
  - 2.2.1 Pair-Trading . . . 6
  - 2.2.2 Mean Reversion . . . 6
  - 2.2.3 Bollinger-Bänder . . . 7
  - 2.2.4 Kalman-Filter . . . 7

**3 Methodik** **9**
- 3.1 Problemstellung und Lösungsansatz . . . 9
- 3.2 Liquiditäts-Baskets . . . 9
- 3.3 Topologisches Clustering . . . 9
  - 3.3.1 Punktwolke und Distanzmetrik . . . 9
  - 3.3.2 Single-Linkage-Clustering als Vietoris-Rips-$H_0$-Filtration . . . 10
  - 3.3.3 Extraktion des persistentesten Clusters . . . 11
- 3.4 Entry- und Exit-Regeln . . . 12
  - 3.4.1 Dynamische Volatilität-gestützte Eintrittsschwellen . . . 13
  - 3.4.2 Stop-Loss . . . 14
  - 3.4.3 Timeout-Exit . . . 14
  - 3.4.4 Struktureller Break als Exit-Regel . . . 15
  - 3.4.5 Dynamische Positionsgrössenbestimmung . . . 15

**4 Implementierung** **17**
- 4.1 Datenbeschaffung . . . 17
  - 4.1.1 Asset-Universum . . . 17
  - 4.1.2 Binance-Abfrage . . . 19
- 4.2 Basket-Konstruktion . . . 21
  - 4.2.1 Rollierendes Volumen . . . 21
  - 4.2.2 Fixe Basket-Schwellen . . . 21
- 4.3 Topologische Parameter . . . 22
  - 4.3.1 Punktwolken-Pipeline . . . 22

4.3.2 Clusterbestimmung . . . 22
4.3.3 Clusteranalyse . . . 23
4.4 Backtest-Engine . . . 25
4.4.1 Aufbau des Backtest-Systems . . . 25
4.4.2 Vermeidung von Look-Ahead-Bias . . . 28
4.5 Hyperparameter-Tuning der Handelsstrategie . . . 29
4.5.1 Ausgewählter Suchraum des finalen Tunings . . . 29

**5 Ergebnisse und Diskussion** **31**
5.1 Backtests . . . 31
5.2 Interpretation . . . 39

**6 Fazit und Ausblick** **41**
6.1 Fazit . . . 41
6.2 Ausblick . . . 41
6.2.1 Multi-Asset-Ansatz nach Lin et al. . . . 41
6.2.2 Kalman-Filter für dynamische Spread-Schätzung . . . 41
6.2.3 Andere Assetklassen . . . 42

**Literaturverzeichnis** **42**

**Hilfsmittelverzeichnis** **45**

**Eigenständigkeitserklärung für schriftliche Arbeiten** **47**

# Abbildungsverzeichnis


2.1 Vietoris-Rips-Filtration eines Beispiels mit zugehörigem $H_0$-Persistenzbarcode . . . . . 5

3.1 Single-Linkage-Dendrogramm des BTC/ETH/SOL-Beispiels . . . . . 12
3.2 Beispiel Bollingerband/Z-Score . . . . . 14

4.1 Anzahl Assets, die täglich Filter 1 und 2 gleichzeitig erfüllen . . . . . 18
4.2 Datenverfügbarkeit der 57 finalen Assets auf Binance . . . . . 20
4.3 Basket-Grösse je Basket (wöchentlicher Median) . . . . . 21
4.4 Verteilung der Persistenzwerte je Basket, mit markiertem 90.-Perzentil als Schwelle . . . . . 23
4.5 Cluster-Grösse je Basket über die Zeit (wöchentlicher Median), kalibrierte Parameter, mit Kalibrierung/Backtest-Split . . . . . 24

5.1 Trades vs. Sharpe Ratio je Basket/Kerzenlängen-Kombination, mit Kosten . . . . . 34
5.2 Trades und Sharpe Ratio je Basket/Kerzenlängen-Kombination im Vergleich, mit Kosten . . 34
5.3 Normierte Equity-Kurven aller 14 Basket/Kerzenlängen-Kombinationen, mit Kosten . . . . 35
5.4 Trades und PnL pro Regime, mit Kosten . . . . . 35
5.5 Trades vs. Sharpe Ratio je Basket/Kerzenlängen-Kombination, kostenfrei . . . . . 37
5.6 Trades und Sharpe Ratio je Basket/Kerzenlängen-Kombination im Vergleich, kostenfrei . . . 37
5.7 Normierte Equity-Kurven aller 14 Basket/Kerzenlängen-Kombinationen, kostenfrei . . . . . 38
5.8 Trades und PnL pro Regime, Kostenfrei . . . . . 38

# Tabellenverzeichnis


3.1 Pearson-Korrelationsmatrix der Returns von BTC, ETH und SOL im Beispielfenster . . . . 11
3.2 Distanzmatrix von BTC, ETH und SOL im Beispielfenster . . . . . 11
3.3 Regimeabhängige Entry-/Exit-Schwellen . . . . . 13

4.1 Konfigurierbarer Suchraum des finalen Tunings pro Basket . . . . . 30

5.1 Je Basket/Kerzenlängen-Kombination tatsächlich getunte Kernparameter . . . . . 31
5.2 Backtest-Ergebnisse 1/2: Performance-Metriken je Basket und Candle-Intervall . . . . . 33
5.3 Backtest-Ergebnisse 2/2: Trade-Statistiken je Basket und Candle-Intervall . . . . . 33
5.4 Backtest-Ergebnisse 1/2 (kostenfrei): Kennzahlen je Basket und Candle-Intervall . . . . . 36
5.5 Backtest-Ergebnisse 2/2 (kostenfrei): Trade-Statistiken je Basket und Candle-Intervall . . . . 36

# Kapitel 1

# Einleitung

Um Pair-Trading zu betreiben, benötigt man zunächst ein paar oder mehrere Assets, die sich korrelierend bewegen. Unsere Arbeit untersucht, ob Topological Data Analysis diese geeignet bestimmen und zusammensetzen kann.

Klassische Ansätze zur Bestimmung solcher Asset-Baskets stützen sich meist auf etablierte Pair-Trading-Verfahren, die auf Kointegration oder Korrelation zwischen jeweils zwei Assets beruhen. Existierende Multi-Asset-Erweiterungen stützen sich dabei meist auf lineare Methoden oder einfache Graph-Neural-Network-Ansätze, die Gruppenzugehörigkeit primär über paarweise, lineare Beziehungen erfassen (vgl. Woo, 2025). TDA wurde in den letzten Jahren erfolgreich auf verschiedene Bereiche der quantitativen Finance angewendet: auf Investitionsentscheidungen (Goel et al., 2020), auf die Früherkennung von Finanzkrisen (Guritanu et al., 2025), auf Clustering und Klassifikation von Finanzzeitreihen (Majumdar and Laha, 2020) sowie speziell auf die Marktstruktur von Kryptowährungen (Rudkin et al., 2023).

## 1.1 Aufgabenstellung

Ziel dieser Arbeit ist die Entwicklung und Implementierung eines Programms, welches mittels eines rollierenden Lookback-Fensters die topologische Struktur von Krypto-Zeitreihen abbildet und daraus Cluster korrelierender Assets bildet, die anschliessend für eine Mean-Reversion-Handelsstrategie verwendet werden können. Die Arbeit umfasst die Datenakquisition, die topologische Datenanalyse sowie die Implementierung eines Pair-Trading-Handelsalgorithmus samt Backtest. Das gesamte Projekt basiert auf Python.

## 1.2 Abgrenzung

Nicht Bestandteil dieser Arbeit ist die Entwicklung eines Live-Traders. Der Backtest beschränkt sich auf eine rein retrospektive Auswertung historischer Daten. Ebenso muss der resultierende Handelsalgorithmus nicht zwangsläufig profitabel sein. Im Vordergrund steht nicht die Maximierung der erzielten Rendite, sondern die Beantwortung der Frage, ob sich mittels Topological Data Analysis stabile, tatsächlich korrelierende Asset-Cluster im Kryptowährungsmarkt identifizieren lassen und ob diese Cluster eine geeignete Grundlage für eine Mean-Reversion-Strategie bilden. Die Profitabilität der Handelsstrategie selbst dient dabei lediglich als ein mögliches Evaluationskriterium, nicht als primäres Ziel der Arbeit.

# Kapitel 2

# Theoretische Grundlagen

## 2.1 Topologische Datenanalyse

Dieser Abschnitt stellt die theoretischen Grundlagen der Topological Data Analysis (TDA) dar. Der Fokus liegt auf der strukturellen Analyse von Finanzzeitreihen sowie auf stabilen topologischen Merkmalen (vgl. Zia et al., 2024).

### 2.1.1 Topologie und Homologie

Topologie untersucht Eigenschaften von geometrischen Objekten, die unter steigender Verformung erhalten bleiben. Auf Datenreihen angewendet bedeutet das, dass Form, Struktur und die Beziehung zwischen den Daten im Vordergrund stehen anstelle von Kennzahlen wie Mittelwert oder Varianz. Zentrale Eigenschaften der TDA sind:

- Fokus auf Struktur statt Einzelwerten
- Robustheit gegenüber Rauschen und Ausreissern
- Keine Annahmen über Wahrscheinlichkeitsverteilungen

(vgl. Zia et al., 2024)

Da reale Datensätze in der Regel aus diskreten Punkten bestehen, wird zunächst eine geometrische Struktur darauf aufgebaut. Diese Struktur wird mithilfe sogenannter simplizialer Komplexe konstruiert. Ein Simplex stellt das einfachste geometrische Objekt einer bestimmten Dimension dar: ein Punkt (0-dimensional), eine Kante (1-dimensional), ein Dreieck (2-dimensional) oder ein Tetraeder (3-dimensional). Ein simplizialer Komplex ist eine Menge solcher Simplizes, die gemeinsam eine geometrische Struktur bilden. In der Praxis wird jeder Datenpunkt als Punkt modelliert. Befinden sich zwei Punkte in räumlicher Nähe, werden sie durch eine Kante verbunden. Sind drei Punkte jeweils paarweise benachbart, entsteht ein Dreieck und entsprechend für höhere Dimensionen. Auf diese Weise wird aus der Punktwolke eine Struktur konstruiert, welche die Zusammenhänge zwischen den Daten repräsentiert und als Grundlage für die topologische Analyse dient (vgl. Zia et al., 2024).

Mithilfe der Homologie lassen sich aus einem simplizialen Komplex topologische Merkmale extrahieren. Die $k$-te Homologiegruppe $H_k$ erfasst dabei die $k$-dimensionalen Löcher eines Raumes:

- $H_0$ zählt die Anzahl der zusammenhängenden Komponenten, also wie viele voneinander getrennte Teile ein Datensatz besitzt.
- $H_1$ zählt die Anzahl unabhängiger eindimensionaler Schleifen, also geschlossener Zyklen, die nicht durch eine Fläche gefüllt sind.
- $H_2$ zählt die Anzahl eingeschlossener zweidimensionaler Hohlräume, zum Beispiel das Innere einer Kugeloberfläche.

Die Dimension von $H_k$ wird als $k$-te Betti-Zahl $\beta_k$ bezeichnet und fasst die jeweilige Homologiegruppe zu einer einzigen Zahl zusammen (vgl. Zia et al., 2024, Abschnitt 2). Höhere Homologiegruppen beschreiben entsprechend Strukturen in noch höheren Dimensionen und spielen vor allem bei hochdimensionalen Daten eine Rolle, allerdings beschränkt sich diese Arbeit ausschliesslich auf $H_0$, da für die Ermittlung der Korrelation der Assets nur die entstehenden Kanten (Zusammenhangskomponenten) relevant sind, nicht die höherdimensionalen Löcher oder Hohlräume, die $H_1$ bzw. $H_2$ erfassen würden.

### 2.1.2 Filtration und persistente Homologie

Ein verbreiteter simplizialer Komplex ist der Vietoris-Rips-Komplex. Für eine Punktwolke $X$ und einen Skalenparameter $\epsilon$ entsteht eine Kante zwischen $i, j \in X$, wenn die Distanz $d(i, j) \leq \epsilon$ ist. Ein höherdimensionaler Simplex entsteht dann, wenn alle paarweisen Distanzen zwischen den Eckpunkten diese Bedingung erfüllen. Der Vietoris-Rips-Komplex ist also der Cluster-Komplex des $\epsilon$-Distanzgraphen. Ein zentrales Problem bei der Konstruktion eines simplizialen Komplexes besteht darin, dass sie von diesem Skalenparameter abhängt. Anstatt einen festen Wert zu wählen, wird deshalb eine Folge von verschachtelten Komplexen betrachtet, die für zunehmend grössere Werte des Skalenparameters entstehen. Das wird als Filtration bezeichnet. Ausgehend von einer Punktwolke werden schrittweise Komplexe konstruiert:

- Zu Beginn ist der Skalenparameter sehr klein, sodass die Daten nur aus isolierten Punkten bestehen.
- Erst wenn der Skalenparameter gross genug ist, werden nahe Punkte miteinander verbunden und Kanten entstehen.
- Mit weiter wachsendem Skalenparameter bilden sich Flächen und höhere Simplizes.

Während der Filtration verändern sich die topologischen Eigenschaften der Daten kontinuierlich. Topologische Merkmale wie Kanten oder Schleifen entstehen erst ab bestimmten Skalen, können miteinander verschmelzen oder bei noch grösseren Werten des Skalenparameters wieder verschwinden (vgl. Zia et al., 2024). Abbildung 2.1 zeigt dies an einem Beispiel mit vier Punkten.

Die persistente Homologie analysiert dabei:

- welche topologischen Merkmale auftreten,
- wann sie entstehen (Geburt),
- wann sie verschwinden (Tod).

Die Dauer zwischen Geburt und Tod eines Merkmals wird als Persistenz bezeichnet. Merkmale mit einer langen Persistenz über einen grossen Skalenbereich hinweg werden als stabil interpretiert und gelten als aussagekräftige Eigenschaften der zugrunde liegenden Datenstruktur. Sie spiegeln in der Regel reale, globale Muster wider, die unabhängig von der genauen Wahl der Skala bestehen bleiben. Im Gegensatz dazu

weisen Merkmale mit sehr kurzer Persistenz oft nur auf lokale Effekte oder auf Rauschen im Datensatz hin und besitzen daher eine geringere Bedeutung für die Analyse und Struktur (vgl. Zia et al., 2024). Eine Darstellung der gesammelten Geburts- und Todeszeitpunkte aller Merkmale wird als Persistenzdiagramm bezeichnet. Dabei handelt es sich nicht um eine einzige feste Darstellungsform, sondern um eine Familie äquivalenter Repräsentationen derselben (Geburt, Tod)-Paare. Am gebräuchlichsten ist der Barcode, bei dem jedes Merkmal als horizontaler Balken über seinen Lebensbereich $[b_i, d_i]$ dargestellt wird (siehe Abbildung 2.1). Für Anwendungen, in denen die Persistenzinformation als Eingabe für maschinelles Lernen vektorisiert werden muss, existieren darüber hinaus weitere Repräsentationen wie Persistence Landscapes oder Persistence Images (vgl. Zia et al., 2024, Abschnitt 2.2–2.3). Wie das Konzept für die vorliegende Arbeit konkret ausgewertet wird, beschreibt Abschnitt 3.3.3. Abbildung 2.1 zeigt die $H_0$-Persistenzen für ein Beispiel mit vier Punkten. Auffällig ist, dass bei $\epsilon = 1{,}6$ kein neuer Balken entsteht: $x_1$, $x_2$ und $x_3$ bilden bereits seit $\epsilon = 1{,}2$ eine gemeinsame Komponente, das Schliessen des Dreiecks ändert daran nichts. $x_4$ dagegen bleibt lange isoliert und verschmilzt erst bei einem deutlich höheren, hier nicht mehr gezeigten $\epsilon$ mit dem übrigen Cluster. Dadurch besitzt der einzelne Punkt $x_4$ rechnerisch sogar die höchste Persistenz im Barcode. Genau deshalb werden Einzelpunkte als Cluster-Kandidaten ausgeschlossen (siehe Abschnitt 3.3.3): Ihre hohe Persistenz ist inhaltlich bedeutungslos, da sie mit keinem anderen Punkt verschmolzen sind. Unter den verbleibenden Kandidaten mit mindestens zwei Mitgliedern ist $\{x_1, x_2, x_3\}$ hier der einzige und damit auch der persistenteste.

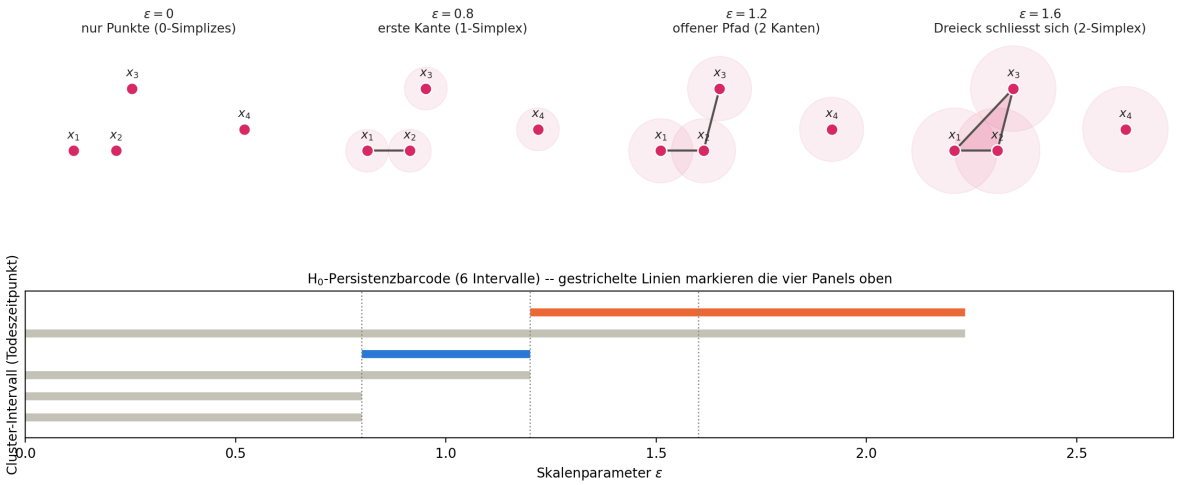



Abbildung 2.1: Vietoris-Rips-Filtration eines Beispiels mit zugehörigem $H_0$-Persistenzbarcode

## 2.2 Pair-Trading als mean-revertierende Handelsstrategie

### 2.2.1 Pair-Trading

Der Return eines einzelnen Assets wird dabei als logarithmierter Return definiert, die Differenz der log-Preise zwischen zwei Zeitpunkten:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(P_t) - \ln(P_{t-1}) \tag{2.1}$$

(vgl. Lin et al., 2021, S. 3, Gl. 5). Diese Definition ist gegenüber dem einfachen Return vor allem wegen ihrer zeitlichen Additivität und der näherungsweisen Symmetrie um Null vorzuziehen. Pair-Trading ist eine marktneutrale Handelsstrategie. Die zentrale Annahme ist, dass zwei Anlagen, die sich langfristig gleich bewegen, bei einer kurzfristigen Divergenz der Preise eine Arbitragemöglichkeit bieten. Die Arbitrage erfolgt auf dem Spread der Returns

$$R_t = r_{A,t} - r_{B,t} \tag{2.2}$$

(vgl. Lin et al., 2021, S. 3, Gl. 6) oder auf dem Spread der Preis-Level

$$\text{spread}_t = \ln(P_{A,t}) - \text{Hedge_Ratio} \cdot \ln(P_{B,t}) \tag{2.3}$$

(vgl. Chan, 2013, S. 64–65, Gl. 3.2). Solange A und B eng gekoppelt sind, oszilliert dieser Spread normalerweise um einen stabilen Mittelwert. Aus dem Spread kann gelesen werden, welche Anlage zur Zeit $t$ relativ über- bzw. unterschätzt ist: Die überschätzte Anlage wird leerverkauft (short), die unterschätzte Anlage gekauft (long). Beide Positionen sind gleich gross, sodass eine allgemeine Marktbewegung sich weitgehend aufhebt. Gewinn/Verlust hängt fast ausschliesslich davon ab, ob sich der Spread wieder normalisiert. Bewegt sich der Spread wieder in Richtung seines üblichen Niveaus, wird die Position geschlossen: Die Short-Seite wird zurückgekauft, die Long-Seite verkauft. Das ist eine marktneutrale Strategie, was bedeutet, dass es nichts ausmacht, sollten beide Assets plötzlich stark fallen, da nur die Differenz der beiden gehandelt wird. Um den Preis-Level-Spread aus Gleichung (2.3) zu bilden, muss zunächst die Gewichtung `hedge_ratio` bestimmt werden, mit der Asset $B$ gegen Asset $A$ gewichtet wird. Diese ergibt sich als Regressionskoeffizient $\hat{\beta}$ einer gewöhnlichen linearen Regression der log-Preise, $\log(P_{A,t}) = \alpha + \beta \log(P_{B,t}) + \varepsilon_t$, wobei OLS (Ordinary Least Squares) $\alpha$ und $\beta$ so bestimmt, dass die Summe der quadrierten Residuen minimal wird (vgl. Chan, 2013, S. 51–54, Beispiel 2.6).

### 2.2.2 Mean Reversion

Um zu beurteilen, ob zwei Assets tatsächlich für Pair-Trading geeignet sind, reicht die Pearson-Korrelation ihrer Returns (Gleichung (3.1)) allein nicht aus. Returns eines Preisprozesses streuen ohnehin meist zufällig um einen Mittelwert von null, unabhängig davon, ob die zugrunde liegenden *Preise* selbst mean-revertierend sind oder nicht. Mean-Reversion von Returns lässt sich daher gar nicht direkt handeln, entscheidend ist stattdessen die Mean-Reversion des *Preisniveaus* bzw. des daraus gebildeten Spreads (vgl. Chan, 2013, S. 39–41). Die Korrelation zweier Return-Reihen kann folglich nicht die langfristige Gleichgewichtsbeziehung zwischen den Preisniveaus zweier Assets quantifizieren. Die tatsächlich relevante Eigenschaft ist Kointegration: Der Preis-Level-Spread aus Gleichung (2.3) muss stationär sein, damit die Annahme einer Rückkehr zum Mittelwert gerechtfertigt ist. Der Cointegrating Augmented Dickey-Fuller-Test (CADF) prüft genau das: Er wendet dieselbe ADF-Regressionsgleichung, die zur Prüfung der Stationarität einer einzelnen Preisreihe verwendet wird (vgl. Chan, 2013, S. 42, Gl. 2.1), nicht auf eine Preisreihe direkt an, sondern auf die Residuen $\varepsilon_t$ der obigen Preis-Regression:

$$\Delta\varepsilon_t = \lambda\varepsilon_{t-1} + \sum_{i=1}^{p} \alpha_i \Delta\varepsilon_{t-i} + u_t \tag{2.4}$$

Die Nullhypothese $H_0$ lautet $\lambda = 0$ (Einheitswurzel, Spread nicht stationär), die Alternativhypothese $H_1$ lautet $\lambda < 0$ (Spread stationär, also mean-revertierend). Das konkrete Vorgehen (Regression und anschliessender Test auf den Residuen) sowie ein durchgerechnetes Zahlenbeispiel zeigt Chan (2013, S. 51–54, Beispiel 2.6). Die Geschwindigkeit der Mean-Reversion lässt sich über die Halbwertszeit quantifizieren. Der Spread wird dazu als Ornstein-Uhlenbeck-Prozess modelliert. In der bei Chan (2013, S. 46–47, Gl. 2.5, Beispiel 2.4) verwendeten Notation gilt

$$dz_t = (\lambda z_{t-1} + \mu)\, dt + d\varepsilon, \tag{2.5}$$

wobei $\lambda$ für einen mean-revertierenden Spread negativ ist und $\lambda$ per linearer Regression von $\Delta z_t$ auf $z_{t-1}$ geschätzt wird. Der Spread pendelt dabei um den Mittelwert $-\mu/\lambda$. Die Halbwertszeit, die erwartete Zeit, bis der Spread die Hälfte seiner Abweichung vom Mittelwert zurückgelegt hat, ergibt sich als

$$\text{Half-Life} = -\frac{\ln(2)}{\lambda}. \tag{2.6}$$

### 2.2.3 Bollinger-Bänder

Um eine als kointegriert identifizierte Paarbeziehung tatsächlich zu handeln, muss der Spread aus Gleichung (2.3) in ein konkretes Entry-/Exit-Signal übersetzt werden. Die Bollinger-Bänder-Methode versieht dazu einen gleitenden Mittelwert des Spreads mit einem Band aus der gleitenden Standardabweichung,

$$\text{Band}_t = \mu_t \pm n_{\text{std}} \cdot \sigma_t \tag{2.7}$$

Ein Überschreiten des oberen bzw. unteren Bands signalisiert eine Entry-Gelegenheit, die Rückkehr in Richtung des Mittelwerts ein Exit-Signal (vgl. Chan, 2013, S. 70–72). Äquivalent dazu lässt sich der Spread über seinen gleitenden Mittelwert und seine gleitende Standardabweichung zu einem Z-Score normieren:

$$z_t = \frac{\text{spread}_t - \mu_t}{\sigma_t} \tag{2.8}$$

$z_t$ gibt an, um wie viele Standardabweichungen der aktuelle Spread vom rollierenden Mittelwert abweicht. Das Überschreiten eines Schwellenwerts $|z_t|$ entspricht damit exakt dem Durchbrechen des jeweiligen Bollinger-Bands (vgl. Chan, 2013, S. 70–72). Die konkrete Parametrisierung, die in dieser Arbeit verwendet wird, folgt in Abschnitt 3.4.

### 2.2.4 Kalman-Filter

Sowohl die Hedge-Ratio aus Abschnitt 2.2.1 als auch der gleitende Mittelwert und die gleitende Standardabweichung der Bollinger-Bänder aus Abschnitt 2.2.3 werden dabei klassischerweise über ein festes rollierendes Fenster geschätzt. Eine dynamischere Alternative bietet der Kalman-Filter: Er interpretiert die Hedge-Ratio als einen sich über die Zeit verändernden, nicht direkt beobachtbaren Zustand und aktualisiert dessen Schätzung sowie die Schätzung von Mittelwert und Varianz des Spreads rekursiv bei jeder neuen Beobachtung, statt bei jedem Zeitschritt die ältesten Beobachtungen eines festen Fensters zu verwerfen (vgl. Chan, 2013, S. 74–81, Gl. 3.5–3.13, Beispiel 3.3). In der vorliegenden Arbeit wird der Kalman-Filter nicht implementiert. Die Gründe dafür sowie eine mögliche Umsetzung als Erweiterung sind im Ausblick beschrieben (Abschnitt 6.2.2).

# Kapitel 3

# Methodik

## 3.1 Problemstellung und Lösungsansatz

Klassisches Pair-Trading setzt voraus, dass zwei Assets bereits als korrelierend bzw. kointegriert identifiziert sind. In der Praxis erfolgt diese Vorauswahl meist manuell oder anhand einmalig festgelegter, statischer Paare. Für Kryptowährungsmärkte ist das problematisch: Die Korrelationsstruktur zwischen Assets ist nicht stabil, sondern verändert sich fortlaufend mit Marktphasen und Liquiditätsverschiebungen. Ein einmal gewähltes Paar bildet die tatsächliche Marktbeziehung deshalb oft schon nach kurzer Zeit nicht mehr ab, und eine manuelle, fortlaufende Neubewertung aller potenziellen Paare ist bei einem Anlageuniversum mit mehreren Dutzend Assets nicht praktikabel.
Die vorliegende Methodik bestimmt handelbare Asset-Gruppen deshalb systematisch und datengetrieben statt manuell. Assets werden zunächst nach Liquidität in Baskets eingeteilt (Abschnitt 3.2), damit die anschliessende Analyse nicht durch den Vergleich sehr liquider mit kaum gehandelten Assets verzerrt wird. Innerhalb jedes Baskets wird für jedes Zeitfenster mittels TDA, konkret über die 0-dimensionale persistente Homologie einer Vietoris-Rips-Filtration, automatisiert ermittelt, welche Assets aktuell am stabilsten gemeinsam co-bewegen (Abschnitt 3.3). Aus dem so gefundenen Cluster werden handelbare Paare gebildet und mit einer Bollinger-Band/Z-Score-Mean-Reversion-Strategie auf dem Preis-Level-Spread gehandelt (Abschnitt 3.4). Löst sich die zugrunde liegende Cluster-Struktur auf, wird die Position unabhängig vom Preissignal zwangsweise geschlossen (Abschnitt 3.4.4).

## 3.2 Liquiditäts-Baskets

Da die Baskets bewusst nach Liquidität getrennt sind, wird das Clustering nicht über das gesamte Asset-Universum hinweg durchgeführt, sondern separat pro Basket. Dies verhindert, dass Korrelationsstrukturen zwischen einem sehr liquiden Asset aus dem liquidesten Basket und einem kaum gehandelten Asset aus dem am wenigsten liquiden Basket die Distanzmatrix verzerren, obwohl beide aus unterschiedlichen Liquiditätsregimen stammen und ohnehin nicht direkt vergleichbar gehandelt werden. Wie die Baskets selbst konkret gebildet werden, beschreibt Abschnitt 4.2 (vgl. Woo, 2026c).

## 3.3 Topologisches Clustering

### 3.3.1 Punktwolke und Distanzmetrik

Zur Analyse der Marktdynamik mehrerer Krypto-Assets mittels topologischer Datenanalyse werden die absoluten Kursveränderungen zunächst in prozentuale Returns umgerechnet. Auf dieser Grundlage wird

eine $n$-dimensionale Punktwolke konstruiert, wodurch die Daten in einen geometrischen Raum überführt werden.
Jeder Zeitschritt wird auf genau einen Punkt abgebildet, der sich in einem Raum mit so vielen Dimensionen bewegt, wie Assets im gegebenen Basket vorhanden sind: Ein Punkt ist damit nicht ein einzelnes Asset über die Zeit, sondern eine Momentaufnahme des gesamten Baskets zu genau diesem Zeitpunkt (vgl. Woo, 2026a). Die Koordinaten eines Punktes entsprechen den Returns aller Assets zu diesem Zeitpunkt. Daraus ergibt sich eine räumliche Distanz, die von der Ähnlichkeit der Marktbewegung abhängt: Zwei Assets liegen umso näher beieinander, je stärker sie sich gleich bewegen.
Um aus der Punktwolke eine für die topologische Analyse nutzbare Struktur zu gewinnen, wird nicht die euklidische Distanz zwischen den Return-Vektoren verwendet, sondern eine auf der paarweisen Korrelation der Assets basierende Distanzmetrik. Für zwei Assets $i$ und $j$ wird zunächst der Pearson-Korrelationskoeffizient ihrer Return-Zeitreihen im betrachteten Fenster direkt aus der Definition berechnet, ohne dass dafür eine Regression nötig wäre:

$$\rho(i,j) = \frac{\sum_t (r_{i,t} - \bar{r}_i)(r_{j,t} - \bar{r}_j)}{\sqrt{\sum_t (r_{i,t} - \bar{r}_i)^2}\sqrt{\sum_t (r_{j,t} - \bar{r}_j)^2}} \tag{3.1}$$

wobei $r_{i,t}$ der Return von Asset $i$ zum Zeitpunkt $t$ ist und $\bar{r}_i$ dessen Mittelwert über das betrachtete Fenster. Aus diesem Korrelationskoeffizienten wird die Distanz definiert als

$$d(i,j) = \sqrt{2\,(1 - \rho(i,j))} \tag{3.2}$$

(vgl. Woo, 2026c) Diese Metrik liegt stets im Bereich $[0, 2]$: Ein Wert von 0 bedeutet perfekte positive Korrelation, also identisches Bewegungsverhalten der beiden Assets im Fenster, $\sqrt{2}$ entspricht keiner linearen Korrelation, und 2 entspricht perfekter negativer Korrelation. Damit übersetzt sich die abstrakte Ähnlichkeit im Marktverhalten direkt in eine geometrische Distanz, die als Eingabe für die Berechnung der persistenten Homologie dient, welche direkt auf dieser vorberechneten Distanzmatrix arbeitet statt auf den Rohkoordinaten der Punktwolke. Wie diese Distanzmatrix in der Praxis pro Zeitfenster und Basket berechnet wird, beschreibt Abschnitt 4.3.1.

### 3.3.2 Single-Linkage-Clustering als Vietoris-Rips-$H_0$-Filtration

Um aus der Distanzmatrix eine hierarchische Struktur zu gewinnen, wird Single-Linkage-Clustering verwendet. Zu Beginn bildet jedes Asset einen eigenen Cluster. In jedem Schritt werden die beiden Cluster mit der geringsten Distanz zueinander verschmolzen, wobei die Distanz zwischen zwei Clustern als die kleinste paarweise Distanz zwischen ihren Mitgliedern definiert ist. Dieser Vorgang wird wiederholt, bis nur noch ein einziger Cluster übrig bleibt, und liefert damit ein Dendrogramm, also eine Baumstruktur, die für jeden Verschmelzungsschritt festhält, welche Cluster bei welcher Distanz zusammengeführt wurden. Dies ist keine Näherung an die eigentlich gesuchte topologische Struktur, sondern mathematisch äquivalent dazu. Beide Verfahren verbinden zwei Punkte, sobald ihre Distanz eine wachsende Schwelle $\epsilon$ unterschreitet, und ein Cluster entsteht, sobald zwei Zusammenhangskomponenten auf diese Weise verschmelzen. Ob diese Schwelle als Filtrationsparameter eines Vietoris-Rips-Komplexes (siehe Abschnitt 2.1.2) oder als Verschmelzungshöhe eines Single-Linkage-Baumes bezeichnet wird, ändert an dieser Merge-Logik nichts: Die 0-dimensionale persistente Homologie eines Vietoris-Rips-Komplexes stimmt deshalb exakt mit dem Dendrogramm des Single-Linkage-Clusterings überein. Diese Äquivalenz erlaubt es, die persistente Homologie nicht bei jedem neuen Zeitfenster vollständig neu zu berechnen, sondern stattdessen direkt mit einem Single-Linkage-Baum zu arbeiten (vgl. Woo, 2026a).

### 3.3.3 Extraktion des persistentesten Clusters

Aus dem Dendrogramm wird pro Fenster genau ein Cluster extrahiert. Für jeden Knoten des Baumes, sowohl die ursprünglichen Assets als Blätter als auch jeden Verschmelzungsschritt, werden eine Geburt und ein Tod definiert. Die Geburt ist die Höhe, bei der der Knoten selbst entstanden ist, also 0 für ein einzelnes Asset und sonst die Distanz des Verschmelzungsschritts, der ihn gebildet hat: Für $H_0$ sind alle Merkmale bereits bei $\epsilon = 0$ geboren, weshalb die Persistenz vollständig durch die Todes-Skala bestimmt ist (vgl. Woo, 2026a). Der Tod ist die Höhe, bei der der Knoten selbst wieder in einen grösseren Cluster verschmilzt. Für die Baumwurzel, die nie weiter verschmilzt, wird der Tod bei einer oberen Distanzschranke $\epsilon_{\max}$ gedeckelt, statt unbeschränkt zu bleiben. Die Persistenz eines Knotens ist die Differenz aus Tod und Geburt. Damit wird aus dem allgemeinen Persistenzdiagramm-Konzept (Abschnitt 2.1.2) für die vorliegende Arbeit gezielt nur der einzelne Knoten mit der grössten Persistenz extrahiert, da für die Identifikation eines handelbaren Clusters ausschliesslich das stabilste zusammenhängende Merkmal von Interesse ist, nicht die vollständige topologische Signatur des Datensatzes. Als Kandidaten für den finalen Cluster gelten alle Knoten mit mindestens zwei Mitgliedern. Einzelne Assets scheiden dabei aus, da ein isoliertes, lange unverschmolzenes Asset rechnerisch eine hohe, aber inhaltlich bedeutungslose Persistenz erreichen kann. Zusätzlich muss die Persistenz eines Kandidaten oberhalb einer Schwelle liegen, deren Kalibrierung in Abschnitt 4.3.2 beschrieben wird. Unter allen Kandidaten gewinnt derjenige mit der grössten Persistenz. Gibt es keinen Kandidaten, wird für dieses Fenster kein Cluster gemeldet. Ein Basket hat damit pro Fenster entweder null oder genau einen Cluster, der aber mehr als zwei Mitglieder umfassen kann, wie das folgende Beispiel zeigt.

#### Beispiel: BTC, ETH und SOL

Zur Veranschaulichung wird der gesamte Weg von der Zeitreihe zum Dendrogramm an drei Assets aus Basket 1 gezeigt, Bitcoin (BTC), Ethereum (ETH) und Solana (SOL), über ein 7-tägiges Fenster endend am 15.06.2025 (Vorgehen nach Woo, 2026a). Aus den prozentualen Returns der drei Assets über dieses Fenster (siehe Sliding-Window-Konstruktion, Abschnitt 4.3.1) ergibt sich mit Gleichung (3.1) folgende Pearson-Korrelationsmatrix der Returns:

| | BTC | ETH | SOL |
|---|---|---|---|
| BTC | 1.0000 | 0.7822 | 0.7796 |
| ETH | 0.7822 | 1.0000 | 0.8113 |
| SOL | 0.7796 | 0.8113 | 1.0000 |

Tabelle 3.1: Pearson-Korrelationsmatrix der Returns von BTC, ETH und SOL im Beispielfenster

Mit der Distanzformel aus Gleichung (3.2) ergibt sich daraus die folgende Distanzmatrix:

| | BTC | ETH | SOL |
|---|---|---|---|
| BTC | 0.0000 | 0.6600 | 0.6639 |
| ETH | 0.6600 | 0.0000 | 0.6143 |
| SOL | 0.6639 | 0.6143 | 0.0000 |

Tabelle 3.2: Distanzmatrix von BTC, ETH und SOL im Beispielfenster

ETH und SOL sind sich in diesem Fenster am ähnlichsten und werden im Single-Linkage-Baum als Erstes zu einem gemeinsamen Cluster verschmolzen. BTC schliesst sich diesem Cluster erst bei der grösseren Distanz

$$\min\big(d(\text{BTC}, \text{ETH}),\ d(\text{BTC}, \text{SOL})\big) = \min(0.6600,\ 0.6639) = 0.6600 \tag{3.3}$$

an, da die Single-Linkage-Regel die Distanz zwischen BTC und dem ETH-SOL-Cluster als die kleinere der beiden Einzeldistanzen definiert. Abbildung 3.1 zeigt das resultierende Dendrogramm für dieses Beispiel. Da die 0-dimensionale persistente Homologie eines Vietoris-Rips-Komplexes exakt mit diesem Single-Linkage-Dendrogramm übereinstimmt, ist dieses Dendrogramm bereits die vollständige $H_0$-Information für das Beispiel, keine Annäherung daran.

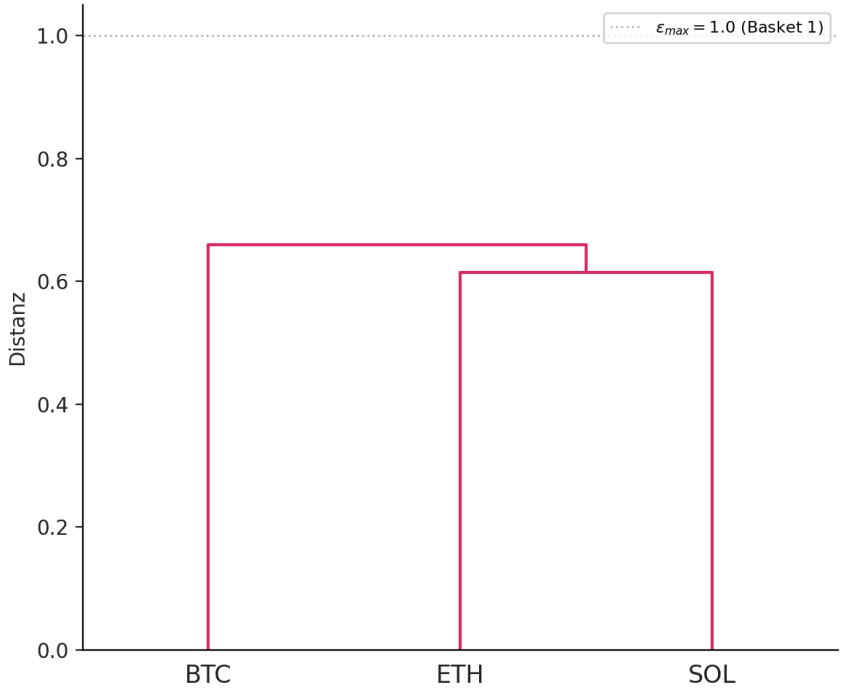



Abbildung 3.1: Single-Linkage-Dendrogramm des BTC/ETH/SOL-Beispiels

Wendet man die Extraktionsregel aus Abschnitt 3.3.3 auf dieses Beispiel an, mit den für Basket 1 kalibrierten Werten $\epsilon_{\max} = 1.0$ und einer Persistenzschwelle von 0.1916 (siehe Kalibrierung der Parameter, Abschnitt 4.3.2), ergeben sich zwei Kandidaten mit mindestens zwei Mitgliedern:

- Der ETH-SOL-Knoten: Geburt 0.6143, Tod 0.6600, also Persistenz 0.0457.
- Die Baumwurzel (alle drei Assets): Geburt 0.6600, bei $\epsilon_{\max}$ gedeckelter Tod 1.0000, also Persistenz 0.3400.

Die Persistenz des ETH-SOL-Knotens liegt unter der Schwelle von 0.1916, jene der Baumwurzel liegt darüber. Es gewinnt die Baumwurzel: Für dieses Fenster wird der gesamte Basket-1-Ausschnitt $\{$BTC, ETH, SOL$\}$ als persistenter Cluster extrahiert.

## 3.4 Entry- und Exit-Regeln

Innerhalb eines Clusters werden jeweils zwei Assets gehandelt (siehe Grundidee Pair-Trading, Abschnitt 2.2). Als konkretes Entry-/Exit-Signal wird die Bollinger-Band/Z-Score-Methode auf dem Preis-Level-Spread verwendet, nicht das Multi-Asset-Toleranzintervall nach Lin et al., das aus Zeitgründen nicht implementiert wurde (siehe Ausblick, Abschnitt 6.2.1).

### 3.4.1 Dynamische Volatilität-gestützte Eintrittsschwellen

Das Problem bei konstanten Entry-/Exit-Schwellen ist, dass die Signifikanz einer Spread-Abweichung vom Volatilitätsumfeld abhängt. Eine Bewegung von 5% ist in stabilen Phasen ein starkes Signal für Mispricing. Jedoch ist dieselbe Bewegung während eines Volatilitätsausbruchs bloss normales Marktverhalten. Statische Schwellen können diese Unterscheidung nicht treffen. Der rollierende Z-Score beachtet das nur teilweise. Der Nenner $\sigma_t$ reagiert auf aktuelle Volatilität. Aber die Schwellen selbst `entry_z` und `exit_z` sind starr. Das hat zwei Konsequenzen:

1. Beim Volatilitätsrückgang sinkt $\sigma_t$, Z-Scores für gleiche absolute Bewegungen steigen, und Signal-Qualität fällt. Das bedeutet: mehr Rauschen, weniger Gewinnpotential pro Trade.

2. Der Anpassungsmechanismus von $\sigma_t$ ist träge. Seine Fenster-Länge bestimmt, wie schnell Regime-Wechsel registriert werden.

Die Lösung ist, die Schwellen direkt an das beobachtete Volatilitätsregime zu koppeln. Dies funktioniert in drei Schritten (vgl. Woo, 2026b).

#### Schritt 1: Realisierte Volatilität des Spreads

Für den Preis-Spread $S_t = \ln(P_A) - \beta \ln(P_B)$ wird die Standardabweichung seiner Änderungen über ein kurzes Fenster (typisch: 1 Tag) berechnet:

$$\sigma_{S,t}^{\text{RV}} = \sqrt{\frac{1}{m} \sum_{i=0}^{m-1} (r_{S,t-i} - \mu_{S,t})^2} \tag{3.4}$$

wobei $r_{S,t} = S_t - S_{t-1}$ der Spread-Return ist. Dies ist das momentane Volatilitätssignal.

#### Schritt 2: Perzentil-basierte Regime-Klassifikation

Über einen längeren Horizont (z. B. 60 Tage) wird die historische Verteilung von $\sigma_{S,t}^{\text{RV}}$ bestimmt und die 20. und 80. Perzentile berechnet:

$$Q_{20,t} = \text{Perzentil}_{20}(\sigma_{S,t-N+1}^{\text{RV}}, \ldots, \sigma_{S,t}^{\text{RV}}) \tag{3.5}$$

$$Q_{80,t} = \text{Perzentil}_{80}(\sigma_{S,t-N+1}^{\text{RV}}, \ldots, \sigma_{S,t}^{\text{RV}}) \tag{3.6}$$

Die Klassifikation erfolgt dann so: Liegt $\sigma_{S,t}^{\text{RV}} \leq Q_{20,t}$ vor, ist der Markt ruhig. Liegt $\sigma_{S,t}^{\text{RV}} \geq Q_{80,t}$ vor, ist er turbulent. Ansonsten ist der Markt normal.

#### Schritt 3: Schwellen-Anpassung

Je nach Regime verschieben sich Entry und Exit um eine Komponente $\Delta b$:

| Regime | Entry | Exit |
|---|---|---|
| Low Vol | $z_{\text{entry}} = b - \Delta b$ | $z_{\text{exit}} = -(b - \Delta b)$ |
| Normal | $z_{\text{entry}} = b$ | $z_{\text{exit}} = -b$ |
| High Vol | $z_{\text{entry}} = b + \Delta b$ | $z_{\text{exit}} = -(b + \Delta b)$ |

Tabelle 3.3: Regimeabhängige Entry-/Exit-Schwellen

**Symmetrischer Exit**

In dieser Arbeit wird der symmetrische Exit verwendet. Das bedeutet, dass der Spread das gegenteilige Bollinger-Band erreicht:

- Short-Eintritt bei $z_t = +b$ (oben), Ausgang bei $z_t = -b$ (unten)
- Long-Eintritt bei $z_t = -b$ (unten), Ausgang bei $z_t = +b$ (oben)

Das bedeutet, dass die Position durch den Mittelwert gehalten wird und das Overshoot auf der anderen Seite erfasst. Die Strategie nutzt so die vollständige Mean-Reversion-Bewegung, nicht bloss die erste Hälfte (vgl. Woo, 2026b).

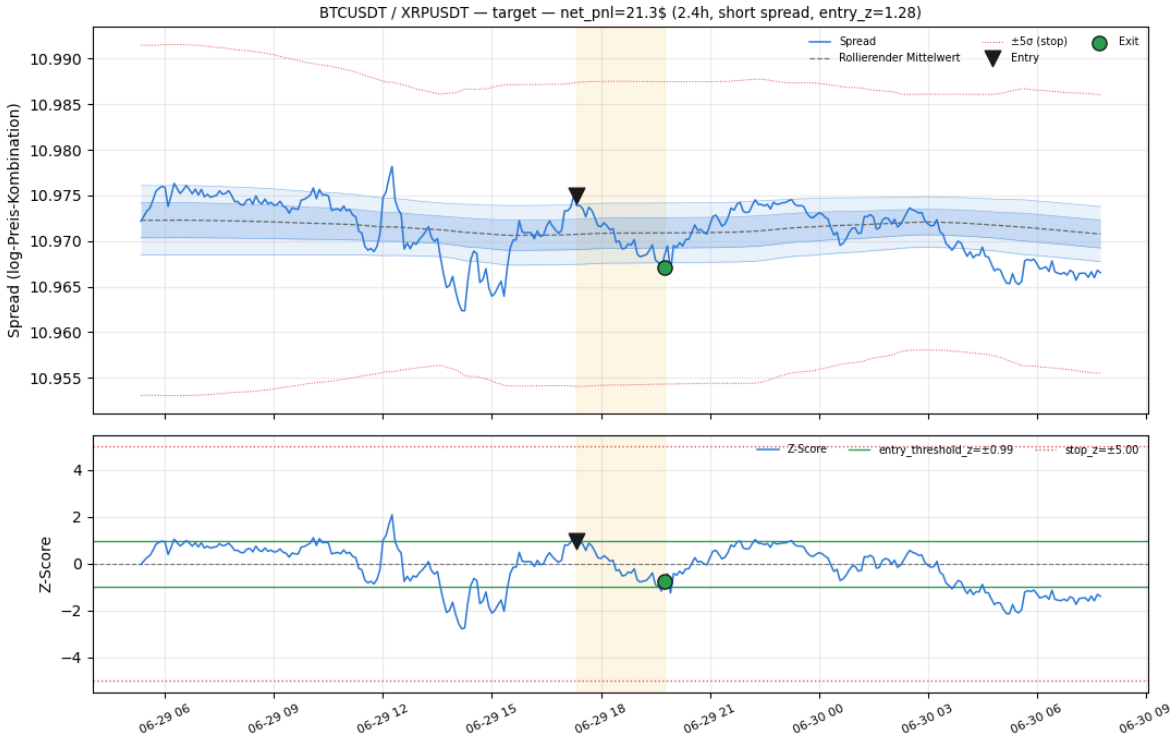



Abbildung 3.2: Beispiel Bollingerband/Z-Score

### 3.4.2 Stop-Loss

Wenn die maximale Holding-Periode den Intraday-Zeitraum überschreitet, ist ein engerer Stop-Loss ein notwendiger Schutzmechanismus. Läuft der Spread stark aus dem erwarteten Band aus, deutet dies auf einen strukturellen Bruch der Paarbeziehung hin und nicht bloss auf eine vorübergehende Abweichung. Diese Regel gilt unabhängig von Volatilitätsregimen (vgl. Woo, 2026b).

### 3.4.3 Timeout-Exit

Neben dem Z-Score-Exit und dem Stop-Loss wird eine Position auch geschlossen, wenn die maximale Holding-Periode `max_holding_candles` überschritten wird, unabhängig davon, wo sich der Z-Score gerade befindet. Dieser Zeit-Exit fängt Fälle ab, in denen der Spread zwar innerhalb der Bollinger-Bänder bleibt, aber über einen langen Zeitraum nicht zum Mittelwert zurückkehrt: Ohne diese Regel bliebe Kapital

unbegrenzt lange in einer nicht-konvergierenden Position gebunden. Da ein zu kurz gewähltes Zeitlimit die Mean-Reversion-Bewegung abschneiden kann, bevor sie sich vollständig entfaltet hat, wird `max_holding_candles` grosszügig genug gewählt, um der Strategie ausreichend Zeit für die Rückkehr zum Mittelwert zu lassen (vgl. Woo, 2026b).

### 3.4.4 Struktureller Break als Exit-Regel

Bei Eintritt in eine Position wird die Todes-Skala $\epsilon^*$ des extrahierten Clusters (Abschnitt 3.3.3) als Referenzwert gespeichert. Während der Haltedauer wird zu jedem Zeitschritt die Distanzmatrix der im Cluster enthaltenen Assets über das aktuelle rollierende Fenster neu berechnet und mittels Single-Linkage zu einem Baum verschmolzen. Dieser Baum wird bei der Schwelle $\tau = \epsilon^* - \delta$ geschnitten, wobei die kleine Toleranz $\delta$ sicherstellt, dass Assets, die exakt bei $\epsilon^*$ verschmolzen sind, nicht fälschlich als noch zusammengehörig gewertet werden. Zerfällt das Cluster bei diesem Schnitt in mehr als eine Komponente, gilt die Cluster-Struktur als gebrochen: Die statistische Grundlage für das gehandelte Paar ist dann nicht mehr gegeben, unabhängig davon, wo sich der Preis-Spread gerade befindet. Die Position wird in diesem Fall sofort geschlossen (vgl. Woo, 2026a).

### 3.4.5 Dynamische Positionsgrössenbestimmung

Da in volatilen Marktphasen die Drawdown-Wahrscheinlichkeit wesentlich höher ist, wird die Positionsgrösse dynamisch berechnet anhand einer Basis-Standardabweichung und einer kurzfristigen Standardabweichung. Das Maximum des Faktors wird dabei aber begrenzt. Die Idee ist, die Positionsgrösse invers proportional zur Spread-Volatilität zu skalieren (vgl. Woo, 2026b):

$$N_t = N_{\text{static}} \cdot \min\left(\frac{\sigma^{\text{RV}}_{S,\text{base}}}{\sigma^{\text{RV}}_{S,t}}, \text{cap}\right) \tag{3.7}$$

Dabei ist:

- $\sigma^{\text{RV}}_{S,\text{base}}$ die Basis-Volatilität des Spreads
- $\sigma^{\text{RV}}_{S,t}$ die aktuelle realisierte Volatilität
- cap ein Sicherheits-Multiplikator, um übermässige Vergrösserung zu verhindern

In hohen Volatilitätsphasen ($\sigma^{\text{RV}}_{S,t} > \sigma^{\text{RV}}_{S,\text{base}}$) wird $N_t < N_{\text{static}}$, was das Risiko reduziert. In ruhigen Phasen kann $N_t$ bis zur Cap-Grenze wachsen. Dies glättet die Gewinn- und Verlustverteilung über verschiedene Marktregime. Die Positionsgrösse wird im Backtest durch den Parameter `sizing_multiplier_cap` gesteuert und ist separat vom Entry-/Exit-Tuning fixiert, um Overfitting zu vermeiden.

# Kapitel 4

# Implementierung

## 4.1 Datenbeschaffung

### 4.1.1 Asset-Universum

#### Kandidatenpool

Zur Bestimmung des zu untersuchenden Anlageuniversums wird der Datenaggregator CoinGecko verwendet. Da CoinGecko keine Möglichkeit bietet, die Top-100-Coins nach Marktkapitalisierung rückwirkend für einen vergangenen Tag abzufragen, wird der Kandidatenpool ausschliesslich aus den zum Abfragezeitpunkt aktuellen Top-100-Coins gebildet, ermittelt durch Sortierung nach Marktkapitalisierung. Stablecoins werden dabei von vornherein aus dem Kandidatenpool entfernt: Ein an den US-Dollar gekoppelter Coin liefert kein handelbares Preissignal, würde mit anderen Stablecoins trivial kointegrieren und in der distanzbasierten Clusterbildung einen trivialen Cluster nahezu identischer, flacher Zeitreihen bilden. Der Kandidatenpool wird dadurch entsprechend kleiner als 100. Diese Vorgehensweise führt zu einem Survivorship-Bias. Da nur der heutige Stand der Top-100-Rangliste verfügbar ist, werden Coins, die im Betrachtungszeitraum zeitweise zu den grössten Kryptowährungen zählten, später jedoch aus den Top 100 herausgefallen sind (z. B. durch einen Kursverfall oder ein Delisting), im Kandidatenpool nicht erfasst. Berücksichtigt werden ausschliesslich jene Coins, die bis zum heutigen Tag in den Top 100 verblieben sind. Dadurch wird der Kandidatenpool systematisch zugunsten von Coins verzerrt, die sich über den gesamten Zeitraum als vergleichsweise stabil bzw. erfolgreich erwiesen haben. Coins mit besonders schlechtem Verlauf sind tendenziell unterrepräsentiert. Für die vorliegende Arbeit wird dieser Effekt in Kauf genommen, da keine historische Alternative mit vertretbarem Mehraufwand zur Verfügung steht.

#### Historische Tageswerte pro Kandidat

Für den gesamten Kandidatenpool wird zusätzlich die historische Tageszeitreihe aus Marktkapitalisierung, Handelsvolumen und Preis über den vollständigen Betrachtungszeitraum von CoinGecko abgefragt. Diese CoinGecko-Tageswerte, nicht die spätere Binance-Zeitreihe, bilden die Datengrundlage für die nachfolgend beschriebene Filterkette. Der verwendete Zeitraum (23.07.2024 bis 22.07.2026, also zwei Jahre) ist keine frei gewählte Fensterlänge, sondern die maximale historische Tiefe, die der verwendete kostenpflichtige CoinGecko-Tarif für diesen Endpunkt bereitstellt. Eine weiter zurückreichende historische Analyse war mit dem verfügbaren Datenzugang somit nicht möglich. Pro Kandidat liefert die API-Abfrage die komplette Tageszeitreihe für den gesamten Zeitraum in einem einzelnen Aufruf. Die Rohdaten werden lokal als Datei abgelegt, damit die nachfolgende Filterung mehrfach durchgeführt werden kann, ohne zusätzliche API-Credits zu verbrauchen.

### Filterkette

Auf Basis dieser Tageswerte wird geprüft, welche Kandidaten drei aufeinanderfolgende Kriterien erfüllen (Woo, 2026c):

1. **Filter 1 (Rang innerhalb des Kandidatenpools)**: Pro Tag werden nur die (höchstens) 100 Coins mit der grössten Marktkapitalisierung innerhalb des bereits survivorship-verzerrten Kandidatenpools behalten. Da der Kandidatenpool durch den vorherigen Ausschluss der Stablecoins bereits kleiner als 100 ist, hat dieser Filter in der aktuellen Konfiguration keine einschränkende Wirkung mehr, jeder verbleibende Kandidat erfüllt ihn automatisch. Er bleibt trotzdem Teil der Filterkette, damit die Obergrenze auch dann greift, wenn der Kandidatenpool (etwa bei einer veränderten Stablecoin-Liste) künftig wieder über 100 Coins umfassen sollte.
2. **Filter 2 (Mindestvolumen)**: Pro Tag werden nur Coins mit einem Handelsvolumen von mehr als 50 Millionen USD an diesem Tag behalten.
3. **Filter 3 (Exchange-Abdeckung)**: Geprüft wird, ob ein Coin auf mindestens 10 der 20 grössten Handelsplätze gehandelt wird. Die 20 grössten Handelsplätze ergeben sich aus dem Spot-Exchange-Ranking von CoinMarketCap. Im Unterschied zu Filter 1 und 2 stützt sich diese Prüfung nur auf den aktuellen Stand und nicht auf tägliche historische Werte, da entsprechende historische Daten zur Exchange-Abdeckung nicht vorliegen.

Filter 1 und 2 sind tagesaufgelöst, Filter 3 dagegen nicht. Erfüllt ein Asset alle drei Filter, zählt es zum finalen Asset-Universum. Gespeichert werden an dieser Stelle zwei Tabellen: das finale Asset-Universum sowie die tägliche Eligibility-Tabelle, die pro finalem Asset nur jene Tage enthält, an denen es tatsächlich Filter 1 und 2 erfüllt hat.

Abbildung 4.1 zeigt die tatsächliche Eligibility im Sinne dieser täglichen Filterung: die Anzahl Assets, die an einem gegebenen Tag Filter 1 und 2 gleichzeitig erfüllen. Filter 3 taucht in dieser Darstellung bewusst nicht auf, da er wie beschrieben keine Tagesauflösung besitzt, sondern nur einmalig über die Zugehörigkeit zum finalen Universum entscheidet. Diese Grösse schwankt über den Betrachtungszeitraum zwischen 26 und 52 Assets bei einem Mittelwert von rund 40. Ein Trend ist dabei nicht erkennbar: Die Anzahl eligibler Assets ist über den gesamten Zeitraum vergleichbar hoch, ohne dass in der jüngeren Vergangenheit systematisch mehr Assets verfügbar wären als weiter in der Vergangenheit. Der in Abschnitt 4.1.1 beschriebene Survivorship-Bias schlägt sich also nicht in einem entsprechenden zeitlichen Trend der Eligibility nieder.

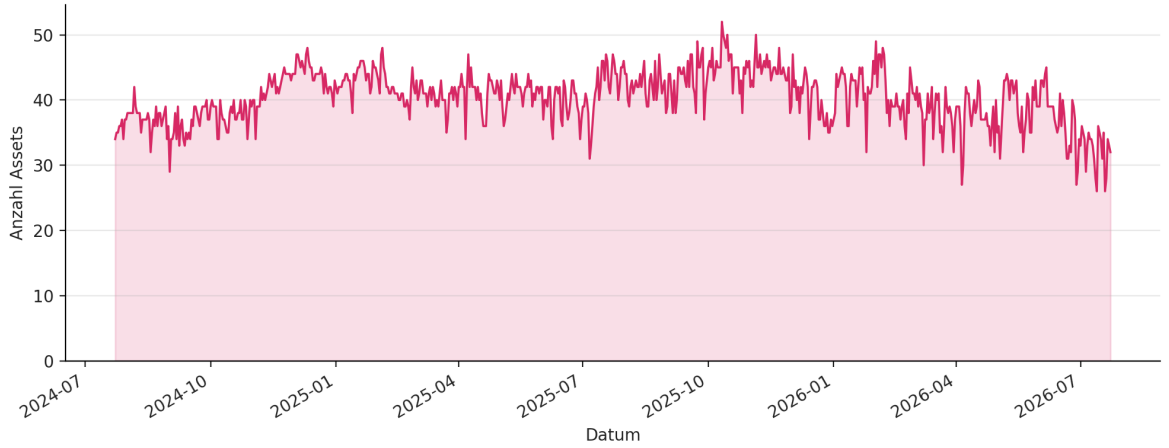



Abbildung 4.1: Anzahl Assets, die täglich Filter 1 und 2 gleichzeitig erfüllen

### 4.1.2 Binance-Abfrage

Im Anschluss wird für alle Assets des finalen Universums geprüft, ob sie auf Binance gehandelt werden. Für die Binance-Abfrage wird bewusst nicht die tagesgenaue Filterung aus der täglichen Asset-Tabelle übernommen. Stattdessen wird für jedes Asset, das zu irgendeinem Zeitpunkt im Betrachtungszeitraum die Filterkriterien erfüllt hat, der gesamte verfügbare Zeitraum auf Binance abgefragt. Dies entkoppelt die eigentliche Datenbeschaffung von der tagesgenauen Eligibility-Filterung und vereinfacht die spätere Arbeit mit den Daten, weil dadurch nie die Frage aufkommt, ob für ein bestimmtes Asset genügend Historie vorhanden ist, um beispielsweise den Lookback zu vergrössern. Um das Handelssymbol auf Binance zu bestimmen, wird nicht einfach das Kürzel des Coins mit dem Suffix `USDT` kombiniert, da manche Coins auf Binance unter einer anderen Symbol-Kombination gelistet sind, was sonst zu Lücken in den abgefragten Daten führen würde. Stattdessen wird das Symbol aus den von CoinGecko bereitgestellten Ticker-Daten aufgelöst, wobei unter den gelisteten Binance-Handelspaaren eine feste Präferenzreihenfolge der Quote-Währung gilt (USDT vor USDC, BUSD, FDUSD, sonst das erste verfügbare Paar). Die Binance-API liefert die Daten als JSON zurück. Aus Gründen der Speichereffizienz und Abfragegeschwindigkeit werden sie in Parquet-Dateien umgewandelt und pro Monat abgelegt.

Die gespeicherten Parquet-Dateien enthalten:

- **`timestamp`**: Unix-Zeitstempel in Millisekunden, Beginn des 5-Minuten-Intervalls (UTC). `1764549300000` → `2025-12-01 03:35:00 UTC`.
- **`market_symbol`**: das Handelspaar auf Binance, z. B. `AAVEUSDT` (AAVE gegen USDT).
- **`open`**: Preis beim Start des Intervalls (erster Trade-Preis in diesen 5 Minuten).
- **`high`**: höchster gehandelter Preis innerhalb des Intervalls.
- **`low`**: niedrigster gehandelter Preis innerhalb des Intervalls.
- **`close`**: Preis am Ende des Intervalls (letzter Trade-Preis).
- **`volume_base`**: gehandeltes Volumen in der Basiswährung
- **`volume_quote`**: gehandeltes Volumen in der Quote-Währung also `volume_base * durchschnittlicher Preis`
- **`trade_count`**: Anzahl einzelner Trades, die in diesem Intervall stattgefunden haben.

Im Anschluss wird die Vollständigkeit der gespeicherten Daten geprüft. Pro Ticker und Kalendertag wird die Anzahl vorhandener Kerzen gegen das theoretische Maximum von 288 Kerzen (24 Stunden zu je 12 Fünf-Minuten-Intervallen) geprüft. Ein Tag mit mindestens 274 Kerzen gilt als vollständig. Da einige Assets historisch noch nicht auf Binance gehandelt wurden, wird für jeden Ticker zunächst das Datum seines ersten Auftretens bestimmt. Tage davor zählen nicht als Lücke und auch der erste Handelstag selbst wird nicht als unvollständig gewertet, da ein Listing in der Regel nicht exakt um Mitternacht UTC erfolgt. Auf Ebene der einzelnen Assets zeigt Abbildung 4.2 die Datenverfügbarkeit, im Unterschied zur täglichen Eligibility aus Abbildung 4.1: Von den 57 Assets im finalen Universum liess sich für 47 ein Binance-Handelspaar auflösen und damit OHLCV-Daten beziehen. Für die übrigen 10 Assets wurde kein passendes Binance-Paar gefunden, weshalb für sie keine OHLCV-Daten vorliegen. Von den 47 Assets mit Daten verfügen 37 über die vollen zwei Jahre Historie ab dem 23.07.2024. Die übrigen 10 beginnen erst später innerhalb des Fensters, weil der jeweilige Coin zu diesem früheren Zeitpunkt entweder noch nicht existierte oder noch nicht auf Binance gehandelt wurde.

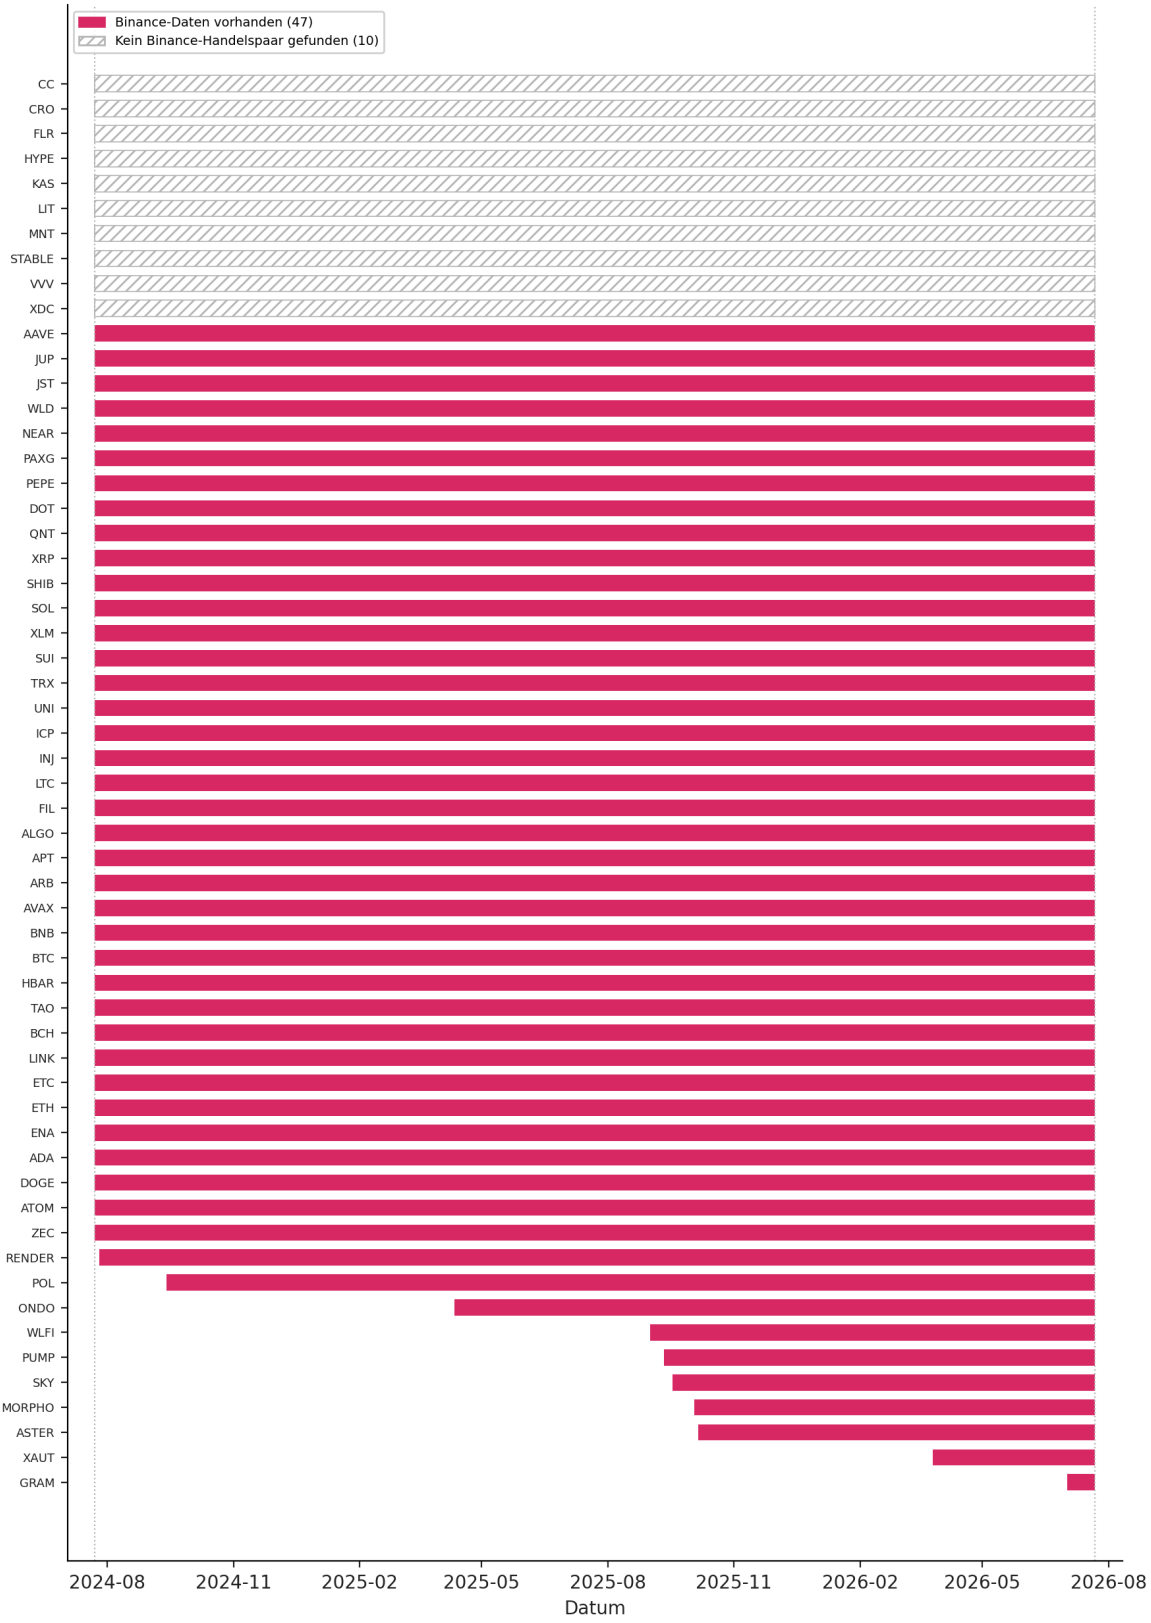



Abbildung 4.2: Datenverfügbarkeit der 57 finalen Assets auf Binance

## 4.2 Basket-Konstruktion

### 4.2.1 Rollierendes Volumen

Nachdem die Rohdaten von Binance vorliegen, werden die Assets in Liquiditäts-Baskets eingeteilt. Grundlage hierfür ist nicht das tägliche Handelsvolumen direkt, sondern ein rollierender Median über 7 Tage. Dies dient dazu, einzelne Volumen-Spitzen zu glätten, die ein Asset sonst kurzzeitig in einen anderen Basket springen lassen würden, obwohl sich dessen tatsächliche Liquidität kaum verändert hat. Als Eingangsdaten dient hierbei die tägliche Asset-Tabelle aus der Datenbeschaffung (Abschnitt 4.1), die dort bereits auf ein Mindestvolumen von 50 Millionen USD gefiltert wurde, sodass für den rollierenden Median selbst keine weitere Filterung mehr nötig ist. Für ein gegebenes Datum wird jedem Asset anhand seines rollenden Medianvolumens genau ein Basket zugewiesen. Da der rollende Median erst ab dem siebten Beobachtungstag definiert ist, beginnt die Basket-Zuweisung entsprechend erst sechs Tage nach Beginn der Historie eines Assets.

### 4.2.2 Fixe Basket-Schwellen

Die Einteilung in Liquiditäts-Baskets erfolgt anhand fixer Volumen-Schwellen:

- **Basket 1**: Volumen $\geq$ \$1,000,000,000
- **Basket 2**: \$250,000,000 $\leq$ Volumen $<$ \$1,000,000,000
- **Basket 3**: \$100,000,000 $\leq$ Volumen $<$ \$250,000,000
- **Basket 4**: \$50,000,000 $\leq$ Volumen $<$ \$100,000,000

Abbildung 4.3 zeigt, wie stark die vier Baskets über den gesamten Betrachtungszeitraum tatsächlich belegt sind (wöchentlicher Median der Anzahl Assets je Basket).

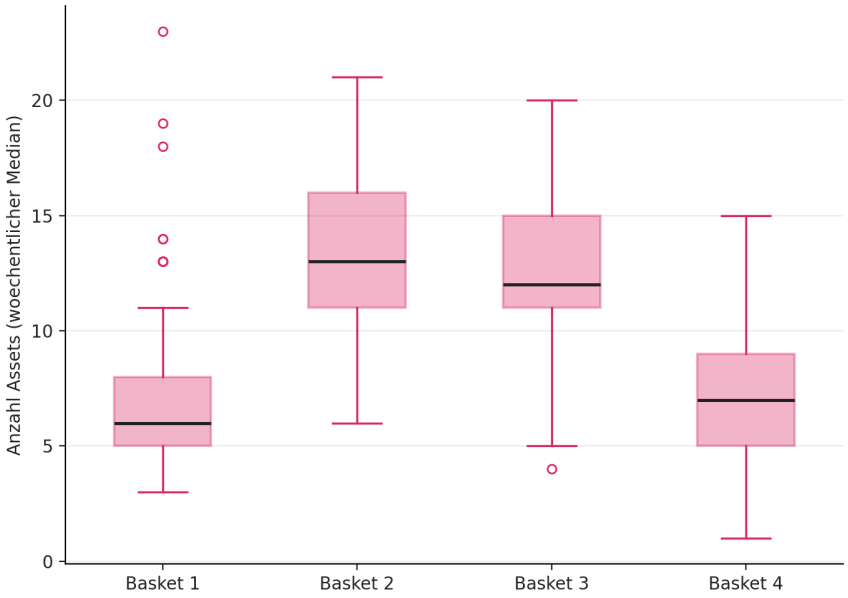



Abbildung 4.3: Basket-Grösse je Basket (wöchentlicher Median)

## 4.3 Topologische Parameter

Für die vorliegende Anwendung wird direkt der Single-Linkage-Baum berechnet (siehe mathematische Äquivalenz zur Vietoris-Rips-$H_0$-Filtration, Abschnitt 3.3.2), statt eine vollständige persistente-Homologie-Bibliothek wie giotto-tda einzusetzen. Da für die vorliegende Arbeit ausschliesslich $\beta_0$ relevant ist (siehe Abschnitt 2.1.1), liefert eine Single-Linkage-Implementierung exakt dasselbe Ergebnis bei deutlich geringerem Rechenaufwand und ohne zusätzliche Abhängigkeit von einer spezialisierten TDA-Bibliothek. Dieser Ansatz, giotto-tda nur einmalig für die initiale Kalibrierung einzusetzen und den laufenden Betrieb stattdessen über `scipy`-Single-Linkage abzuwickeln, folgt (Woo, 2026a).

### 4.3.1 Punktwolken-Pipeline

Die Definition der Korrelations-Distanzmetrik, auf der die Punktwolken-Konstruktion aufbaut, findet sich in Abschnitt 3.3.1. Bevor die Korrelationsmatrix in Distanzen umgerechnet wird, wird sie zusätzlich numerisch abgesichert. NaN-Werte, die z. B. bei einem konstanten Return-Verlauf eines Assets entstehen können, werden auf 0 gesetzt, und Rundungsfehler, die $\rho$ knapp aus dem gültigen Bereich $[-1, 1]$ herausdrücken könnten, werden per Clipping korrigiert. Erst danach wird die Wurzel gezogen, wobei negative Werte unter der Wurzel (ebenfalls ein möglicher Rundungsfehler-Effekt) durch ein Maximum mit 0 abgefangen werden.

#### Sliding-Window-Konstruktion

Die Punktwolke wird nicht einmalig über den gesamten Betrachtungszeitraum gebildet, sondern pro Zeitfenster neu aufgebaut. Für ein gegebenes Enddatum wird ein Fenster fester Länge, gemessen in Kalendertagen, zurückgerechnet, wobei sich die tatsächlich verwendeten Assets aus dem an diesem Datum gültigen Universum ergeben (siehe Basket-Konstruktion, Abschnitt 4.2). Die 5-Minuten-Schlusskurse innerhalb dieses Fensters werden zu einer Preis-Matrix der Form Zeitstempel $\times$ Assets pivotiert. Assets, die innerhalb des Fensters zu viele fehlende Werte aufweisen (weniger als 95 % nicht-NaN-Zeitstempel), werden aus dem Fenster entfernt, ebenso Zeitstempel, an denen danach noch immer mindestens ein Asset fehlt. Dies stellt sicher, dass jede Punktwolke auf einer vollständigen, lückenlosen gemeinsamen Zeitachse basiert, statt implizit über fehlende Werte hinweg zu interpolieren. Aus der bereinigten Preis-Matrix werden anschliessend die prozentualen Returns berechnet. Fenster mit weniger als drei verbleibenden Zeitstempeln oder weniger als zwei verbleibenden Assets werden verworfen, da eine sinnvolle Korrelationsberechnung mehrere Zeitpunkte voraussetzt und eine Distanzmatrix ohne mindestens zwei Assets nicht definiert ist.

#### Getrennte Punktwolken pro Basket

Für jedes Fenster wird zunächst bestimmt, welche Assets an diesem Datum zum jeweiligen Basket gehören (siehe Abschnitt 4.2). Alle übrigen Assets werden von der Punktwolken-Konstruktion ausgeschlossen. Enthält ein Basket an einem Datum weniger als zwei Assets, wird für dieses Basket-Fenster keine Punktwolke gebildet. Die methodische Begründung, warum überhaupt separat pro Basket geclustert wird, findet sich in Abschnitt 3.3.

### 4.3.2 Clusterbestimmung

Der in Abschnitt 3.3 beschriebene Algorithmus hat drei freie Parameter pro Basket: die Fensterlänge der Punktwolke, die obere Distanzschranke $\epsilon_{\max}$ und die Persistenzschwelle. Alle drei werden ausschliesslich anhand eines Kalibrierungszeitraums bestimmt, die letzten 20 % der verfügbaren Historie bleiben davon unangetastet und dienen später ausschliesslich dem Backtest. $\epsilon_{\max}$ wird nicht empirisch gesucht, sondern inhaltlich begründet auf 1.0 gesetzt. Mit der Distanzformel aus Gleichung (3.2) entspricht das ei-

ner Pearson-Korrelation von $\rho = 0.5$: Nur Assets mit mindestens moderater positiver Korrelation sollen überhaupt als potenziell verbunden gelten. Die Fensterlänge wird über die Stabilität der gefundenen Cluster-Mitglieder zwischen zwei nicht überlappenden Fenstern bestimmt: Ein Vergleich gegen unmittelbar benachbarte, überlappende Fenster würde längere Fensterlängen allein dadurch stabiler aussehen lassen, dass sie mehr Rohdaten teilen, ohne dass die gefundenen Cluster deshalb inhaltlich robuster wären, weshalb bewusst nicht überlappende Fenster verglichen werden. Die tatsächlich verwendete Fensterlänge wird von Hand gewählt. Für die vier Baskets ergeben sich so 7, 10, 15 beziehungsweise 5 Tage. Basket 1 und Basket 4 erhalten damit die kürzesten Fenster. Die Persistenzschwelle wird über ein Histogramm bestimmt. Für den Kalibrierungszeitraum werden je Basket die Persistenzwerte aller Kandidaten-Knoten gesammelt, nicht nur der jeweilige Gewinner, um die Verteilung aus Rauschen und potenziell echtem Signal sichtbar zu machen, wie in Abbildung 4.4 für alle vier Baskets gezeigt. Da sich darin keine klare Lücke zwischen beiden Bereichen zeigt, wird als pragmatischer Kompromiss je Basket das 90. Perzentil der beobachteten Werte als Schwelle verwendet, sodass nur die persistentesten 10 % aller Kandidaten überhaupt zu einem gemeldeten Cluster führen können. Sowohl die histogrammbasierte Wahl der Persistenzschwelle als auch die Grössenordnung der Fensterlänge orientieren sich an den Parameterempfehlungen in (Woo, 2026c).

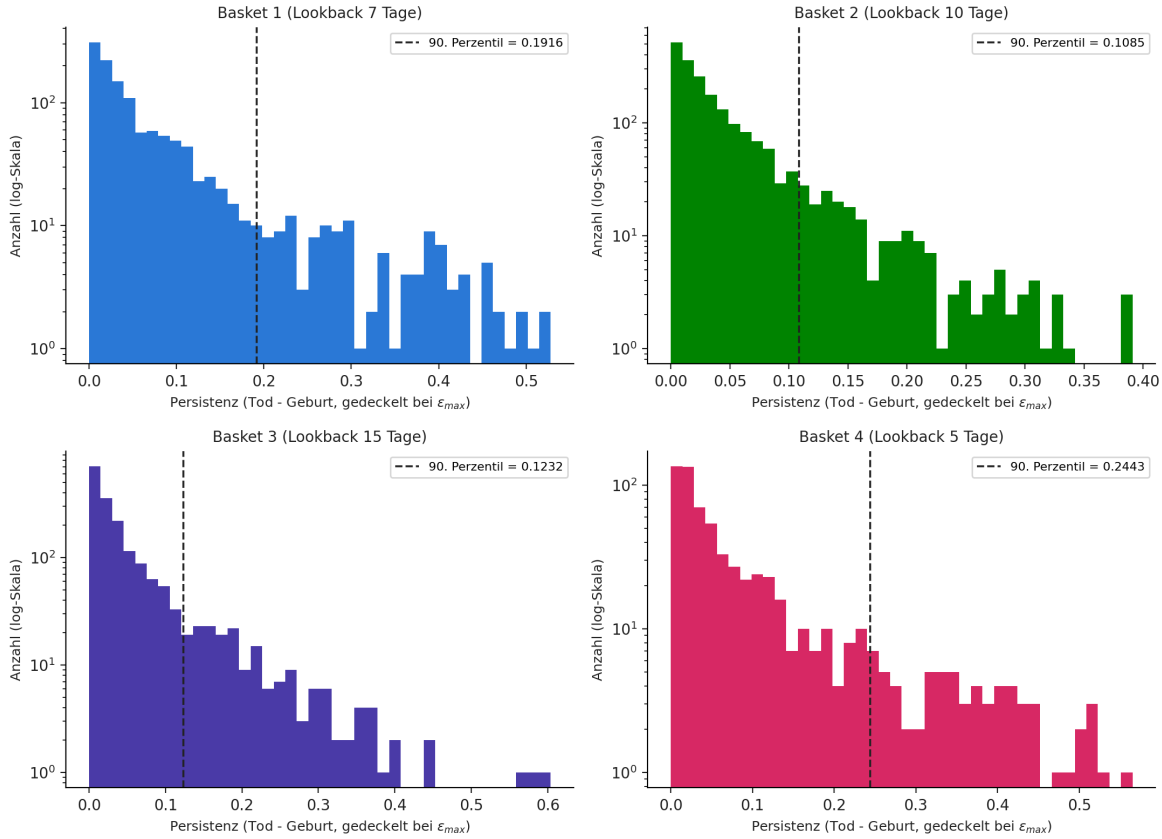



Abbildung 4.4: Verteilung der Persistenzwerte je Basket, mit markiertem 90.-Perzentil als Schwelle

### 4.3.3 Clusteranalyse

Mit den kalibrierten Parametern lässt sich für jeden Basket und jedes Abtastintervall verfolgen, wie gross der jeweils extrahierte Cluster über die Zeit ist, und an welchem Anteil der Zeitpunkte überhaupt kein Cluster über der Persistenzschwelle liegt. Abbildung 4.5 zeigt dieses Bild für alle vier Baskets, mit den jeweils

kalibrierten Parametern (Lookback und Persistenzschwelle je Basket gemäss Abbildung 4.4, $\epsilon_{\max} = 1.0$). Über den gesamten Betrachtungszeitraum liegt an 27,2 % (Basket 1), 17,1 % (Basket 2), 35,6 % (Basket 3) beziehungsweise 70,3 % (Basket 4) der Tage kein Cluster über der Persistenzschwelle. Die gestrichelte Linie markiert das Ende des Kalibrierungszeitraums: Basket 1 bis 3 liefern auch im reinen Backtest-Zeitraum rechts davon durchgehend Cluster, Basket 4 dagegen produziert dort an keinem einzigen Tag mehr einen Cluster über der Schwelle. Das ist die eigentliche, methodisch begründete Rechtfertigung für den Ausschluss von Basket 4: Nicht weil dem Basket häufig Assets fehlen, sondern weil selbst bei ausreichender Asset-Anzahl keine hinreichend persistente Korrelationsstruktur gefunden wird, aus der sich ein handelbares Paar ableiten liesse, und diese Struktur im Out-of-Sample-Zeitraum vollständig verschwindet. Basket 4 wird deshalb von der weiteren Analyse ausgeschlossen. Die verbleibende Arbeit betrachtet ausschliesslich Basket 1 bis 3.

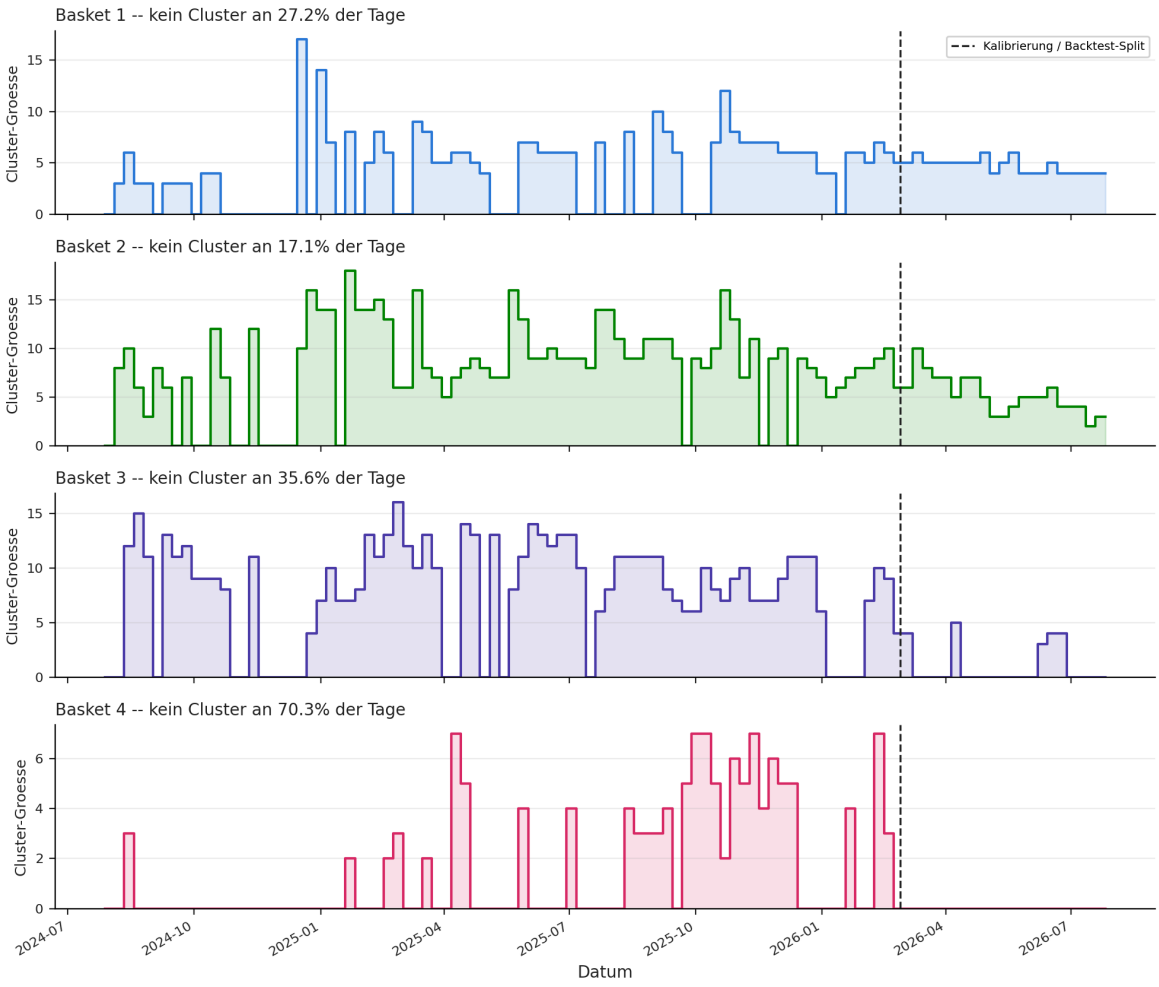



Abbildung 4.5: Cluster-Grösse je Basket über die Zeit (wöchentlicher Median), kalibrierte Parameter, mit Kalibrierung/Backtest-Split

## 4.4 Backtest-Engine

### 4.4.1 Aufbau des Backtest-Systems

Das Backtest-System gliedert sich in sechs Module: die Datenpipeline, die Signalgenerierung, die Handelsstrategie, die Ausführungs-Engine, das Portfolio- und Kostenmodell sowie die Auswertungs- und Konfigurationsschicht.

#### Datenpipeline und Grundstruktur

Als Grundlage dienen Kerzendaten (Open, High, Low, Close) im Fünf-Minuten-Raster, welche pro Kalendermonat als eigenständige Datendatei abgelegt sind. Beim Laden eines Zeitraums wird daraus ein sogenanntes Panel gebildet: ein Wörterbuch, das pro Preisfeld (Open, High, Low, Close) eine Tabelle mit den Zeitstempeln als Zeilenindex und den Marktsymbolen als Spalten enthält. Fehlende Kerzen (zum Beispiel bei neu gelisteten Symbolen) werden nicht entfernt, sondern als fehlende Werte im vollständigen Zeitraster belassen, damit ein einzelnes lückenhaftes Symbol nicht den gesamten Betrachtungszeitraum verkürzt. Andere Kerzenlängen (zehn, fünfzehn, dreissig, sechzig oder zweihundertvierzig Minuten) werden nicht separat gespeichert, sondern zur Laufzeit aus dem Fünf-Minuten-Basisraster resampelt. Vor der eigentlichen Simulation wandelt die Engine das Panel intern vollständig in numerische Arrays um. Dieser Schritt entfernt den Pandas-Verwaltungsaufwand aus der Bar-für-Bar-Schleife, welche andernfalls bei mehreren Hunderttausend Iterationen pro Lauf spürbar langsamer wäre.

#### Signalgenerierung: Bildung und Prüfung der Paare

Die Auswahl handelbarer Wertpapierpaare stützt sich auf sogenannte Cluster: Gruppen von Vermögenswerten, die anhand einer korrelationsbasierten Distanz und persistenter Homologie (topologische Datenanalyse) als zusammengehörig erkannt wurden. Diese Cluster werden nicht innerhalb der Backtest-Engine berechnet, sondern vorgelagert erzeugt und als Zeitreihe von Momentaufnahmen (Snapshots) zwischengespeichert. Die Engine liest diese Snapshots nur noch ein. Innerhalb eines aktiven Clusters bildet die Strategie alle möglichen Zweierkombinationen der enthaltenen Symbole. Da die Anzahl möglicher Paare bei grossen Clustern schnell zweistellig oder höher wird, erfolgt zunächst eine Vorfilterung anhand der absoluten Rendite-Korrelation: Nur eine konfigurierbare Anzahl der am stärksten korrelierten Paare wird für die aufwendigere Prüfung weiterverwendet. Für jedes verbliebene Kandidatenpaar wird auf einem rollierenden Kalibrierungsfenster folgende Kette von Berechnungen durchgeführt:

1. Schätzung des Hedge-Ratios per gewöhnlicher kleinster Quadrate (OLS) auf den logarithmierten Preisen des einen Symbols gegen die des anderen.

2. Bildung des Preis-Spreads als Differenz der logarithmierten Preise, gewichtet mit dem geschätzten Hedge-Ratio.

3. Prüfung der Stationarität dieses Spreads mittels Augmented-Dickey-Fuller-Test und, als Gegenprobe, mittels Kwiatkowski-Phillips-Schmidt-Shin-Test.

4. Berechnung des Hurst-Exponenten als zusätzliches Mass für die Mean-Reversion-Neigung.

5. Schätzung der Half-Life aus einem angepassten Ornstein-Uhlenbeck-Modell: Die Differenz des Spreads wird linear auf den um eine Periode verzögerten Spread-Wert regressiert, und aus dem geschätzten Rückkehrkoeffizienten wird die Anzahl Kerzen berechnet, nach welcher im Erwartungswert die Hälfte einer Abweichung abgebaut ist.

Ein Paar wird nur dann als handelbare Spread-Definition übernommen, wenn der Stationaritätstest ein positives Ergebnis liefert und die geschätzte Half-Life innerhalb eines konfigurierten Bandes liegt. Von den verbleibenden Kandidaten werden pro Cluster-Snapshot maximal so viele Paare mit der kürzesten Half-Life behalten, wie ein konfigurierbares Limit erlaubt. Das Hedge-Ratio sowie sämtliche Diagnosewerte werden zum Zeitpunkt dieser Formation eingefroren und für die gesamte Lebensdauer der daraus entstehenden Position unverändert weiterverwendet. Ein erneutes Schätzen während einer offenen Position findet nicht statt. Für die laufende Bewertung während des Haltens einer Position wird ein zweites, deutlich kürzeres rollierendes Fenster verwendet, welches Mittelwert und Standardabweichung des Spreads liefert. Der daraus abgeleitete Z-Score ist die zentrale Grösse, auf der sämtliche Entry- und Exit-Entscheidungen basieren.

### Handelsstrategie

Die implementierte Basisstrategie generiert bei jeder Bar für jede aktive Spread-Definition ein Signal, sobald der Betrag des aktuellen Z-Scores eine Entry-Schwelle überschreitet. Das Vorzeichen des Z-Scores bestimmt die Richtung: Ein positiver Wert (Spread über dem Mittelwert) löst ein Short-Signal auf den Spread aus, ein negativer Wert ein Long-Signal. Mehrere gleichzeitig auslösende Signale werden nach der Stärke des Z-Scores priorisiert. Es werden nur so viele tatsächlich eröffnet, wie freie Positionsplätze vorhanden sind. Zwei Erweiterungen gegenüber der klassischen, statischen Regel wurden implementiert und sind über Konfigurationsschalter unabhängig voneinander aktivierbar:

**Symmetrischer Ausstieg.** Ist dieser Modus aktiv, verwendet die Ausstiegsprüfung nicht die feste Schwelle aus der Konfiguration, sondern denjenigen Schwellenwert, welcher bei der Eröffnung dieser konkreten Position tatsächlich gültig war und in den Positionsdaten gespeichert wurde. Die Position wird erst geschlossen, sobald der Z-Score, multipliziert mit der Handelsrichtung, diesen Wert erreicht oder überschreitet. Dies entspricht dem Halten bis zum gegenüberliegenden Band statt bis zur Rückkehr zur Mitte.

**Dynamische, volatilitätsabhängige Schwelle und Positionsgrösse.** Ist dieser Modus aktiv, wird bei der Formation zusätzlich eine rollierende Realized-Volatility-Reihe der Spread-Renditen über ein langes Referenzfenster berechnet und daraus der Median sowie das zwanzigste und achtzigste Perzentil bestimmt. Bei jeder Signalprüfung wird anschliessend die aktuelle, kurzfristige Realized Volatility mit diesen beiden Perzentilgrenzen verglichen. Liegt sie unterhalb der unteren Grenze, wird die Entry-Schwelle um einen konfigurierten Betrag verringert. Liegt sie oberhalb der oberen Grenze, wird sie um denselben Betrag erhöht. Dazwischen bleibt die Basisschwelle unverändert. Zusätzlich wird bei aktivierter dynamischer Positionsgrösse das Verhältnis von medianer zu aktueller Realized Volatility als Multiplikator auf die sonst feste Positionsgrösse angewendet, nach oben begrenzt durch eine konfigurierbare Obergrenze, um bei sehr geringer aktueller Volatilität keine übermässig grosse Position zu öffnen. Da beide Mechanismen dieselbe Volatilitätsschätzung verwenden, entsteht nur eine einzige, konsistente Datenquelle für äktuelle Marktverfassungïnnerhalb der Strategie.

### Ausstiegsregeln

Neben der strategieeigenen Z-Score-Ausstiegsregel prüft die Engine bei jeder Bar zusätzlich eine Kette engine-weiter, strategieunabhängiger Ausstiegsregeln, welche unabhängig voneinander konfiguriert werden können:

- Eine feste Stop-Schwelle auf den Betrag des Z-Scores, welche nicht volatilitätsadjustiert ist und bei Überschreiten eine sofortige Zwangsschliessung auslöst.
- Ein zeitlicher Ausstieg, sollte die maximale Haltedauer überschritten werden.

- Ein optionaler Ausstieg bei erkanntem topologischem Strukturbruch, welcher auf einem separaten Single-Linkage-Clustering-Verfahren beruht (Ansatz nach Woo, 2026a).
- Ein Zwangsausstieg bei Datenlücken, falls für ein Symbol über eine konfigurierte Anzahl Kerzen keine Preise vorliegen.

Alle offenen Positionen, die am Ende des simulierten Zeitraums noch bestehen, werden zum letzten verfügbaren Schlusskurs zwangsweise geschlossen, damit die Auswertung keine offenen, unbewerteten Positionen enthält.

#### Ablauf der Bar-für-Bar-Simulation

Die Engine verarbeitet den gewählten Zeitraum in einer einzigen Schleife über den vollständigen Kerzenindex. Innerhalb jeder Bar werden folgende Schritte in fester Reihenfolge ausgeführt:

1. Ausführung sämtlicher Order, die in einer vorherigen Bar zur Ausführung vorgemerkt wurden.
2. Neubewertung aller offenen Positionen zum aktuellen Kerzenpreis.
3. Vorrücken des Cluster-Zeigers je Basket auf den zum aktuellen Zeitpunkt gültigen Snapshot.
4. Prüfung aller offenen Positionen auf Ausstieg, zunächst gegen die engine-weite Regelkette, danach gegen die strategieeigene Regel.
5. Generierung neuer Einstiegssignale je Basket, sofern freie Positionsplätze vorhanden sind, gefolgt von der Prüfung, ob die verfügbare Kapazität (maximales Bruttoengagement, maximale Positionsanzahl) eine Eröffnung überhaupt zulässt.
6. Schreiben einer Zeile der Equity-Kurve mit Kapitalstand, realisiertem Gewinn und Verlust, kumulierten Kosten, Bruttoengagement und Anzahl offener Positionen je Basket.

#### Positionsführung

Jede Position besteht aus mehreren *Legs* (z. B. Long Asset A, Short Asset B bei einem Pair-Trade), dollarneutral gewichtet. Gewinn/Verlust entsteht ausschliesslich durch die fortlaufende Neubewertung der offenen Legs, wodurch eine doppelte PnL-Zählung vermieden wird. Als Ausgangskapital dient in allen Backtests \$100 000. Jede Position nutzt standardmässig 10 % des aktuellen Eigenkapitals als Bruttonotional (Compounding), wobei das gesamte Bruttoengagement über alle offenen Positionen hinweg 100 % des Eigenkapitals nicht übersteigen darf.

#### Positionsverwaltung und Kapitalbuchhaltung

Bei Eröffnung einer Position wird das gewünschte Bruttonotional als Anteil des aktuellen Eigenkapitals berechnet, multipliziert mit dem gegebenenfalls dynamisch bestimmten Sizing-Multiplikator. Dieses Notional wird auf die einzelnen Beine (Legs) des Spreads verteilt: Ist Dollar-Neutralität aktiviert, erhält die Summe der Long-Beine und die Summe der Short-Beine je die Hälfte des Bruttonotionals. Andernfalls erfolgt die Aufteilung proportional zu den Beträgen der Hedge-Ratio-Gewichte. Aus dieser Aufteilung und dem jeweiligen Ausführungspreis ergibt sich die zu handelnde Stückzahl je Bein.

Der Kapitalstand wird konsistent gehalten, ohne den Gewinn oder Verlust doppelt zu verbuchen: Bei Eröffnung wird lediglich das Notional zum Barguthaben hinzu- beziehungsweise abgezogen, samt der dabei anfallenden Kosten. Der eigentliche Gewinn oder Verlust entsteht ausschliesslich durch die laufende Neubewertung der offenen Positionen zum jeweils aktuellen Marktpreis. Bei Schliessung wird das Notional wieder gegen Barguthaben getauscht, abzüglich der Ausstiegskosten.

#### Transaktionskostenmodell

Für jede Order (Entry und Exit je Position) werden Kosten in Form einer Handelsgebühr sowie eines Slippage-Aufschlags auf das gehandelte Notional berechnet:

$$C = N \cdot \left( \frac{f_{\text{bps}}}{10\,000} + \frac{s_{\text{bps}}}{10\,000} \right) \tag{4.1}$$

wobei $N$ das Notional der Order (Preis $\times$ Menge), $f_{\text{bps}}$ die Handelsgebühr in Basispunkten und $s_{\text{bps}}$ der Slippage-Aufschlag in Basispunkten ist. Als Standardwerte werden $f_{\text{bps}} = 10$ (entsprechend dem Taker-Satz von 0,10 % auf Binance Spot (Binance, 2026)) sowie $s_{\text{bps}} = 2$ verwendet. Der Slippage-Aufschlag lässt sich wahlweise als fester Satz in Basispunkten oder als von der relativen Handelsspanne der Ausführungskerze abhängiger Betrag konfigurieren. Letzteres bildet die tatsächliche Illiquidität eines Marktes zum Ausführungszeitpunkt ab, statt einen geschätzten festen Wert zu unterstellen, was insbesondere bei dünn gehandelten Vermögenswerten relevant ist. Für die in dieser Arbeit berichteten Ergebnisse wird jedoch durchgehend der feste Satz $s_{\text{bps}} = 2$ verwendet. Die Kosten fallen sowohl beim Öffnen als auch beim Schliessen einer Position an. Sie werden direkt vom verfügbaren Kapital abgezogen bzw. bei Schliessung von der Gutschrift einbehalten und mindern damit den realisierten Gewinn/Verlust des jeweiligen Trades. Für Vergleichszwecke lässt sich zusätzlich ein vollständig kostenfreier Lauf konfigurieren, bei welchem sowohl $f_{\text{bps}}$ als auch $s_{\text{bps}}$ auf null gesetzt werden, um den Anteil der durch Handelskosten aufgezehrten Rendite sichtbar zu machen (siehe Abschnitt 5.1 für den direkten Vergleich mit und ohne Kosten).

#### Auswertung

Aus der resultierenden Equity-Kurve und dem vollständigen Handelsprotokoll werden nach Abschluss eines Laufs sämtliche Kennzahlen berechnet, darunter annualisierte Rendite, annualisierte Volatilität, Sharpe-, Sortino- und Calmar-Ratio, maximaler Drawdown samt Zeitpunkt und Dauer, Gewinnquote, Profit-Faktor, durchschnittliche und mediane Haltedauer, Aufschlüsselung nach Ausstiegsgrund sowie der Anteil der Handelskosten am Bruttogewinn. Die Annualisierung berücksichtigt dabei explizit die tatsächlich verwendete Kerzenlänge, da Kryptowährungen im Gegensatz zu klassischen Börsenprodukten durchgehend rund um die Uhr gehandelt werden und somit kein Kalender mit Handelstagen zugrunde liegt.

### 4.4.2 Vermeidung von Look-Ahead-Bias

Zur Absicherung gegen unbeabsichtigten Zukunftsdatenzugriff implementiert die Engine mehrere strukturelle Schutzmechanismen:

- **Ausführungs-Lag**: Signal auf Kerze $t$ führt frühestens zu einem Fill auf Kerze $t + 1$.
- **Preisfenster-Cutoff**: Die Strategie kann strukturell nicht über die aktuelle Kerze hinaus auf Preisdaten zugreifen.
- **Eingefrorene Schätzer**: Statistische Schätzungen (z. B. Hedge-Ratio) werden bei Positionseröffnung fixiert und während der Haltedauer nicht nachgefittet.
- **Warm-up-Guard**: Vor Backtest-Start muss ausreichend Preishistorie vorhanden sein, um die Formationsfenster der Strategie zu füllen.

## 4.5 Hyperparameter-Tuning der Handelsstrategie

Sämtliche Strategie- und Ausführungsparameter sind in einer einzigen, unveränderlichen Konfigurationsstruktur zusammengefasst und lassen sich pro Basket individuell überschreiben. Die Parametersuche erfolgt getrennt vom abschliessenden Auswertungszeitraum. Ein fester Anteil der jeweils neuesten verfügbaren Daten wird für die endgültige Validierung reserviert und fliesst zu keinem Zeitpunkt in die Parametersuche ein. Für die Optimierung der Hyperparameter der Handelsstrategie wurde das Optuna-Framework verwendet, da es keine Grid Search nutzt. Diese würde bei mehreren Hyperparametern, welche für die Auswertung jeweils pro Kombination einen kompletten Backtest benötigen, viel zu teuer werden. Optuna nutzt dazu sequenzielle bayessche Optimierung, welche den Suchraum gezielter anhand von Wahrscheinlichkeitsdichten eingrenzt, statt ihn blind abzutasten. Man definiert eine Zielfunktion, das `objective`. Dann erhält Optuna eine Reihe an Parameterwerten. Mit diesen Werten führt es einen Backtest auf einem definierten Bereich durch, jedoch über mehrere Zeitfenster. Der Backtest für eine Parameterkombination läuft dabei nicht nur über einen einzigen Zeitraum, sondern über mehrere aufeinanderfolgende, nicht überlappende Zeitfenster innerhalb des Kalibrierungszeitraums, die sogenannten Folds. Für jeden Fold wird mit derselben Parameterkombination ein eigener Backtest durchgeführt, was pro Fold eine eigene Rendite liefert. Erst danach werden diese Rendite-Werte zum eigentlichen Objective zusammengefasst. Das wird so gemacht, um sicherzugehen, dass die Strategie nicht nur in einer Marktphase funktioniert. Würde man stattdessen nur einen einzigen, langen Zeitraum verwenden, könnte eine Kombination rein zufällig gut passen, ohne dass sie tatsächlich robust ist. Zum Ende wird das Objective zurückgegeben, was in diesem Fall der Mean-Return minus Standardabweichung ist:

$$\text{Objective} = \overline{R} - \sigma_R \tag{4.2}$$

wobei $\overline{R}$ der mittlere Return über die Zeitfenster und $\sigma_R$ dessen Standardabweichung ist. Es wurde so gewählt, um sehr volatile, nicht konstante Returns abzustrafen. Kandidaten, die über sämtliche Fenster zusammen eine zu geringe Anzahl an Transaktionen erzeugen, werden vor der Bewertung verworfen, da eine kaum handelnde Strategie unter der gewählten Zielgrösse sonst systematisch begünstigt würde, ohne tatsächlich eine bessere Handelsregel darzustellen.

### 4.5.1 Ausgewählter Suchraum des finalen Tunings

Für das Tunen kann jeder Parameter individuell festgelegt werden, ob er Teil der Optuna-Suche ist (*tunen*) oder auf einem fixen Wert gehalten wird. Tabelle 4.1 listet alle auf diese Weise konfigurierbaren Parameter, ihren jeweiligen Wert bzw. Suchbereich sowie ihre Bedeutung. Die fixierte Stop-Loss-Schwelle sowie der Suchbereich der maximalen Haltedauer folgen den Empfehlungen aus (Woo, 2026b).
Die Auswahl, welche Parameter tatsächlich optimiert und welche fix gehalten werden, folgt derselben in Abschnitt 5.1 dargelegten Überlegung zum Data-Snooping-Bias. Fensterparameter mit primär statistischer Begründung (Formationsfenster, Vol-Regime-Fenster, Perzentilgrenzen) sowie Risiko-Caps (Stop-Loss-Schwelle, maximale Haltedauer, Sizing-Cap) werden nicht gegen die In-Sample-Performance optimiert, sondern aus theoretischen bzw. praktischen Erwägungen fixiert. Optimiert werden dagegen jene Parameter, für die keine eindeutige theoretische Vorgabe existiert und die unmittelbar die Handelslogik bestimmen: die Entry-Schwelle, deren volatilitätsabhängige Anpassung, die Grenzen der zulässigen Half-Life sowie die maximale Anzahl gleichzeitiger Positionen.

| **Parameter** | **Fixwert / Suchbereich** | **Bedeutung** |
|---|---|---|
| $z_{\text{entry}}$ | 0.30 – 4.00 (tunen) | Z-Score-Schwellenwert für den Entry. |
| $\Delta z_{\text{entry}}$ | 0.05 – 1.00 (tunen) | Additive Verschiebung der Entry-/Exit-Schwelle in Abhängigkeit vom Volatilitätsregime des Spreads. |
| $z_{\text{stop}}$ | 5.00 (fix) | Stop-Loss-Schwelle auf Z-Score-Ebene. |
| Max. Haltedauer | 4.00 Tage (fix) | Absoluter Zeit-Cap pro Position. |
| Sizing-Multiplikator-Cap | 4.00 (fix) | Obergrenze für die volatilitätsabhängige Skalierung der Positionsgrösse. |
| Vol-Regime-Lookback | 1.00 Tage (fix) | Fenstergrösse $m$ der rollierenden Realized-Volatility-Schätzung des Spreads. |
| Vol-Regime-Perzentilfenster | 35.00 Tage (fix) | Länge $N$ der Referenzverteilung, aus der die Perzentilgrenzen für die Regimeklassifikation bestimmt werden. |
| Vol-Regime unteres Perzentil | 20.00 (fix) | Perzentilschwelle, unterhalb derer ein Low-Volatility-Regime erkannt wird. |
| Vol-Regime oberes Perzentil | 80.00 (fix) | Perzentilschwelle, oberhalb derer ein High-Volatility-Regime erkannt wird. |
| Formationsfenster | 20.00 Tage (fix) | Kalibrierungsfenster für Hedge-Ratio, ADF-Test und Half-Life. |
| Min. Half-Life | 1.00 – 6.00 Std. (tunen) | Untere Grenze der zulässigen Mean-Reversion-Half-Life. |
| Max. Half-Life | 3.00 – 15.00 Tage (tunen) | Obere Grenze der zulässigen Mean-Reversion-Half-Life. |
| Max. gleichzeitige Positionen | 1 – 15 (tunen) | Obergrenze der Anzahl gleichzeitig offener Positionen pro Basket. |

Tabelle 4.1: Konfigurierbarer Suchraum des finalen Tunings pro Basket

# Kapitel 5

# Ergebnisse und Diskussion

## 5.1 Backtests

### Fixe Parameter

Acht der insgesamt 13 im Widget-Panel konfigurierbaren Parameter wurden bei allen 14 untersuchten Basket/Kerzenlängen-Kombinationen fix gehalten und nicht Teil der Optuna-Suche, siehe Tabelle 4.1.

| Basket | Kerze | $z_{\text{entry}}$ | $\Delta z_{\text{entry}}$ | Min Half-Life | Max Half-Life | Max Pos. |
|---|---|---|---|---|---|---|
| 1 | 5 min | 0.988 | 0.057 | 72 Kerzen = 6.00 Std. | 2215 Kerzen = 7.69 Tage | 10 |
| 1 | 10 min | 0.376 | 0.971 | 31 Kerzen = 5.17 Std. | 799 Kerzen = 5.55 Tage | 3 |
| 2 | 5 min | 2.388 | 0.695 | 34 Kerzen = 2.83 Std. | 3503 Kerzen = 12.16 Tage | 13 |
| 2 | 10 min | 1.298 | 0.666 | 17 Kerzen = 2.83 Std. | 897 Kerzen = 6.23 Tage | 13 |
| 2 | 15 min | 1.273 | 0.172 | 17 Kerzen = 4.25 Std. | 1146 Kerzen = 11.94 Tage | 13 |
| 2 | 30 min | 0.877 | 0.105 | 11 Kerzen = 5.50 Std. | 490 Kerzen = 10.21 Tage | 11 |
| 2 | 60 min | 0.376 | 0.971 | 5 Kerzen = 5.00 Std. | 133 Kerzen = 5.54 Tage | 3 |
| 2 | 240 min | 0.412 | 0.555 | 2 Kerzen = 8.00 Std. | 79 Kerzen = 13.17 Tage | 13 |
| 3 | 5 min | 2.233 | 0.560 | 60 Kerzen = 5.00 Std. | 3296 Kerzen = 11.44 Tage | 13 |
| 3 | 10 min | 1.686 | 0.953 | 28 Kerzen = 4.67 Std. | 1467 Kerzen = 10.19 Tage | 3 |
| 3 | 15 min | 1.289 | 0.339 | 11 Kerzen = 2.75 Std. | 485 Kerzen = 5.05 Tage | 9 |
| 3 | 30 min | 0.979 | 0.339 | 7 Kerzen = 3.50 Std. | 393 Kerzen = 8.19 Tage | 5 |
| 3 | 60 min | 0.700 | 0.527 | 5 Kerzen = 5.00 Std. | 313 Kerzen = 13.04 Tage | 5 |
| 3 | 240 min | 0.312 | 0.565 | 2 Kerzen = 8.00 Std. | 72 Kerzen = 12.00 Tage | 13 |

Tabelle 5.1: Je Basket/Kerzenlängen-Kombination tatsächlich getunte Kernparameter

### Backtestergebnisse je Basket und Kerzenlänge

Mit den in Tabelle 5.1 dokumentierten, kalibrierten Parametern wurden für alle 14 Basket/Kerzenlängen-Kombinationen Out-of-Sample-Backtests durchgeführt. Tabelle 5.2 und 5.3 zeigen die daraus resultierenden Performance- und Trade-Kennzahlen je Kombination. Für Basket 1 liegen nur die Kerzenlängen 5 und 10 Minuten vor, da die restlichen Kerzenlängen im Training nie die nötigen 100 Trades pro Fold zustande kamen. Dies lässt sich durch Abbildung 4.5 erklären. Basket 1 hat im Testzeitraum viele Lücken, was in der Tuningphase zu weniger Trades führt.

- **CAGR** (annualisierte Rendite) ist die geometrisch annualisierte Wachstumsrate der Equity-Kurve über den Validierungszeitraum. Ein durchgehend negativer Wert bedeutet, dass die Strategie im untersuchten Zeitraum systematisch Kapital verloren hat.
- **Ann. Vol.** (annualisierte Volatilität) ist die annualisierte Standardabweichung der täglichen Renditen der Equity-Kurve und misst die Schwankungsbreite der Strategie, unabhängig von deren Richtung.

- **Sharpe** (Sharpe Ratio) setzt die annualisierte Überrendite gegenüber dem risikofreien Zins ins Verhältnis zur annualisierten Volatilität und ist damit die zentrale Kennzahl für risikoadjustierte Performance. Sie ist definiert als

$$\text{Sharpe} = \frac{R_p - R_f}{\sigma_p}, \tag{5.1}$$

  wobei $R_p$ die annualisierte Rendite der Strategie, $R_f$ der risikofreie Zins und $\sigma_p$ die annualisierte Volatilität der Strategierenditen bezeichnet. Ein hoher positiver Wert zeigt an, dass die erzielte Überrendite im Verhältnis zum eingegangenen Risiko gross ausfällt, während negative Werte auf eine risikoadjustiert schlechtere Strategie hindeuten, deren Rendite die eingegangene Volatilität nicht rechtfertigt. Für Krypto-Anlagen existiert kein etablierter risikofreier Referenzzins wie z. B. bei US-Treasuries im Aktienbereich, weshalb in dieser Arbeit $R_f = 0$ gesetzt wird. Die Sharpe Ratio reduziert sich damit auf das Verhältnis von annualisierter Rendite zu annualisierter Volatilität.

- **Sortino** (Sortino Ratio) ist analog zum Sharpe Ratio aufgebaut, bezieht sich bei der Risikomessung im Nenner jedoch ausschliesslich auf die Abwärtsvolatilität (negative Renditen) und bestraft damit im Gegensatz zum Sharpe Ratio keine positive Schwankung.

- **Calmar** (Calmar Ratio) setzt die annualisierte Rendite ins Verhältnis zum maximalen Drawdown und misst damit die Rendite je Einheit des schlimmsten historisch eingetretenen Kapitalrückgangs.

- **Max DD** (Maximum Drawdown) ist der grösste prozentuale Rückgang der Equity-Kurve von einem bisherigen Höchststand bis zu ihrem darauffolgenden Tiefpunkt über den Validierungszeitraum.

- **Trades** ist die absolute Anzahl abgeschlossener Positionen im Validierungszeitraum.

- **Win Rate** (Trefferquote) ist der Anteil der Trades mit positivem Netto-Ergebnis (nach Kosten) an der Gesamtzahl der Trades.

- **Profit Factor** ist das Verhältnis der Summe aller Gewinne zur Summe aller Verluste. Ein Wert unter 1 bedeutet, dass die kumulierten Verluste die kumulierten Gewinne übersteigen.

- **Ø Haltedauer (h)** ist die durchschnittliche Haltedauer einer Position in Stunden, vom Entry bis zum Exit.

| Basket | Candle (min) | CAGR | Ann. Vol. | Sharpe | Sortino | Calmar | Max DD |
|---|---|---|---|---|---|---|---|
| Basket 1 | 5 | -12.40% | 1.98% | -6.671 | -7.249 | -2.420 | -5.66% |
| Basket 1 | 10 | -25.91% | 2.39% | -12.546 | -10.796 | -2.307 | -11.46% |
| Basket 2 | 5 | -7.15% | 1.94% | -3.818 | -4.288 | -1.950 | -3.89% |
| Basket 2 | 10 | -13.08% | 2.14% | -6.529 | -6.836 | -2.350 | -5.63% |
| Basket 2 | 15 | -11.43% | 2.06% | -5.873 | -6.539 | -2.275 | -5.29% |
| Basket 2 | 30 | -15.83% | 2.89% | -5.958 | -5.910 | -2.382 | -6.90% |
| Basket 2 | 60 | -19.82% | 4.90% | -4.482 | -4.496 | -2.356 | -8.68% |
| Basket 2 | 240 | -20.90% | 3.23% | -7.238 | -7.050 | -2.350 | -8.97% |
| Basket 3 | 5 | -8.27% | 2.14% | -4.014 | -3.950 | -2.453 | -3.48% |
| Basket 3 | 10 | -8.64% | 2.22% | -4.069 | -4.019 | -2.450 | -3.65% |
| Basket 3 | 15 | -8.68% | 2.21% | -4.103 | -4.063 | -2.450 | -3.71% |
| Basket 3 | 30 | -9.73% | 3.47% | -2.935 | -2.913 | -2.442 | -4.16% |
| Basket 3 | 60 | -9.87% | 3.57% | -2.890 | -2.881 | -2.321 | -4.36% |
| Basket 3 | 240 | -9.53% | 1.91% | -5.241 | -5.111 | -2.443 | -3.91% |

Tabelle 5.2: Backtest-Ergebnisse 1/2: Performance-Metriken je Basket und Candle-Intervall

Ergänzend dazu fasst Tabelle 5.3 die zugehörigen Trade-Statistiken.

| Basket | Candle (min) | Trades | Win Rate | Profit Factor | Ø Haltedauer (h) |
|---|---|---|---|---|---|
| Basket 1 | 5 | 268 | 42.91% | 0.383 | 15.5 |
| Basket 1 | 10 | 452 | 24.34% | 0.163 | 9.4 |
| Basket 2 | 5 | 170 | 46.47% | 0.589 | 22.3 |
| Basket 2 | 10 | 264 | 45.08% | 0.437 | 16.7 |
| Basket 2 | 15 | 233 | 45.92% | 0.489 | 18.7 |
| Basket 2 | 30 | 253 | 44.66% | 0.359 | 17.4 |
| Basket 2 | 60 | 311 | 39.23% | 0.319 | 13.9 |
| Basket 2 | 240 | 222 | 36.49% | 0.264 | 18.0 |
| Basket 3 | 5 | 28 | 21.43% | 0.182 | 18.3 |
| Basket 3 | 10 | 46 | 36.96% | 0.193 | 12.9 |
| Basket 3 | 15 | 42 | 28.57% | 0.132 | 15.5 |
| Basket 3 | 30 | 41 | 34.15% | 0.118 | 14.3 |
| Basket 3 | 60 | 41 | 46.34% | 0.111 | 11.4 |
| Basket 3 | 240 | 52 | 30.77% | 0.126 | 14.5 |

Tabelle 5.3: Backtest-Ergebnisse 2/2: Trade-Statistiken je Basket und Candle-Intervall

Über alle 14 Kombinationen hinweg zeigt sich damit ein konsistentes Bild: Trotz optimierter Hyperparameter und annähernder Marktneutralität erzielt keine der untersuchten Basket/Kerzenlängen-Kombinationen eine positive risikoadjustierte Rendite im Backtest-Zeitraum.

Abbildung 5.1 bis 5.3 veranschaulichen dieses Ergebnis grafisch für die kostenpflichtige Variante:
Basket 1 fällt am stärksten negativ auf (Sharpe Ratio bis $-12.5$ bei 10-Minuten-Kerzen), es lassen sich auch ein klarer Trend erkennen, was ein Zusammenhang der Anzahl Trades und des Sharp-Ratios nahelegt, das die Strategie zu stark von den Handelskosten abhängt.

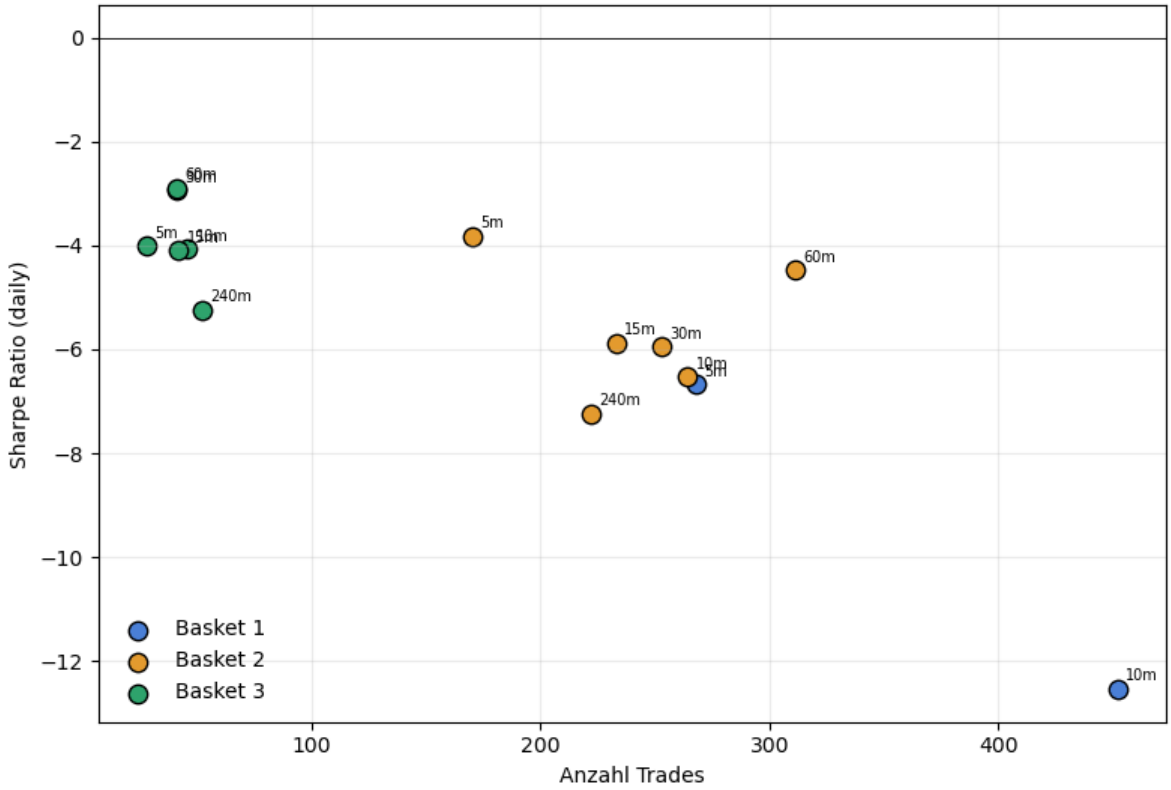



Abbildung 5.1: Trades vs. Sharpe Ratio je Basket/Kerzenlängen-Kombination, mit Kosten

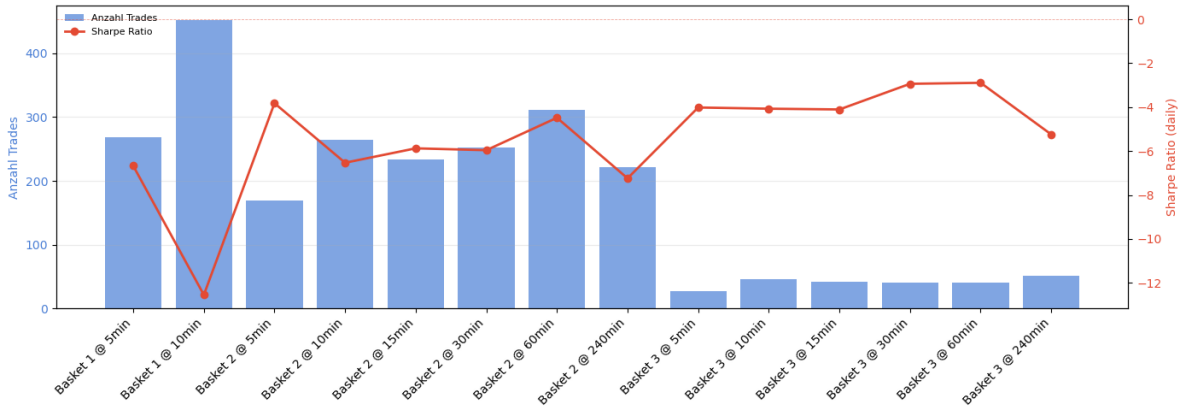



Abbildung 5.2: Trades und Sharpe Ratio je Basket/Kerzenlängen-Kombination im Vergleich, mit Kosten

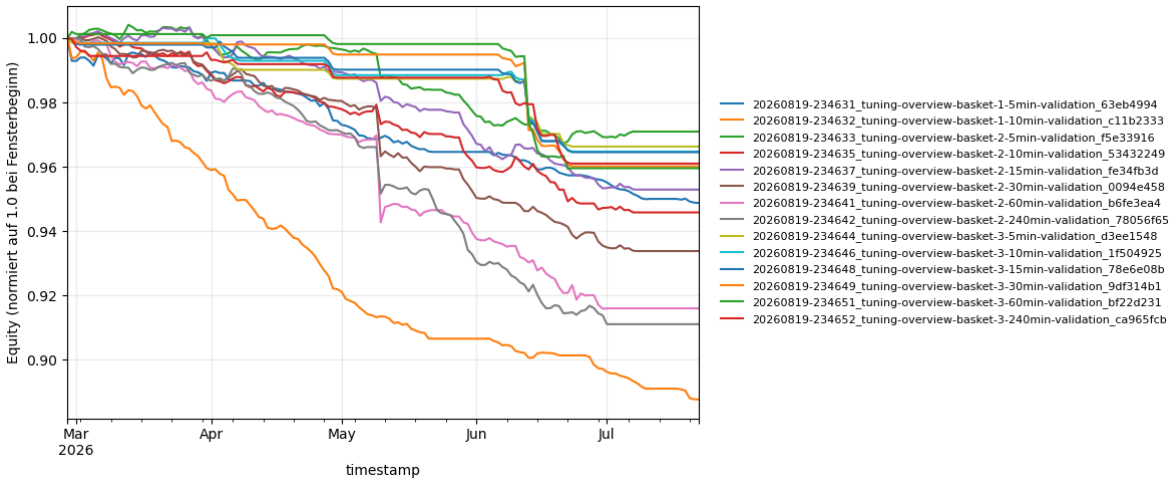



Abbildung 5.3: Normierte Equity-Kurven aller 14 Basket/Kerzenlängen-Kombinationen, mit Kosten

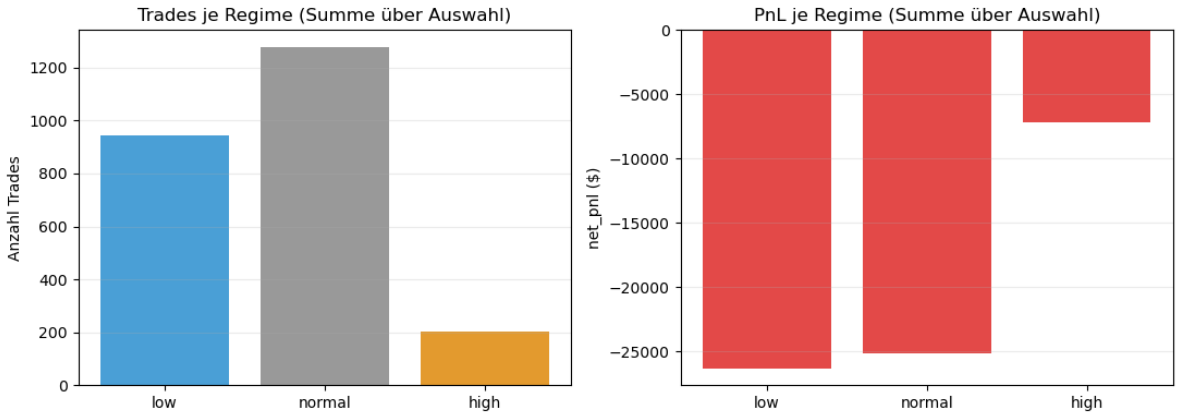



Abbildung 5.4: Trades und PnL pro Regime, mit Kosten

| Basket | Candle (min) | CAGR | Ann. Vol. | Sharpe | Sortino | Calmar | Max DD |
|---|---|---|---|---|---|---|---|
| Basket 1 | 5 | 6.31% | 2.35% | 2.616 | 4.839 | 6.014 | -1.20% |
| Basket 1 | 10 | 4.68% | 2.33% | 1.969 | 3.507 | 4.222 | -1.19% |
| Basket 2 | 5 | 4.29% | 1.99% | 2.117 | 3.077 | 2.545 | -1.85% |
| Basket 2 | 10 | 4.36% | 2.21% | 1.937 | 2.867 | 4.353 | -1.12% |
| Basket 2 | 15 | 3.33% | 2.32% | 1.425 | 2.196 | 1.969 | -1.82% |
| Basket 2 | 30 | -0.14% | 3.00% | -0.032 | -0.038 | -0.056 | -2.68% |
| Basket 2 | 60 | 0.69% | 4.86% | 0.165 | 0.181 | 0.258 | -3.29% |
| Basket 2 | 240 | -6.28% | 3.31% | -1.941 | -2.181 | -1.487 | -4.32% |
| Basket 3 | 5 | -6.60% | 2.04% | -3.343 | -3.338 | -2.466 | -2.81% |
| Basket 3 | 10 | -5.64% | 2.03% | -2.854 | -2.899 | -2.326 | -2.72% |
| Basket 3 | 15 | -6.01% | 2.04% | -3.023 | -3.102 | -2.304 | -2.79% |
| Basket 3 | 30 | -7.15% | 3.38% | -2.178 | -2.183 | -2.445 | -3.13% |
| Basket 3 | 60 | -6.93% | 3.43% | -2.074 | -2.095 | -2.194 | -3.25% |
| Basket 3 | 240 | -5.47% | 1.65% | -3.405 | -3.512 | -2.444 | -2.38% |

Tabelle 5.4: Backtest-Ergebnisse 1/2 (kostenfrei): Kennzahlen je Basket und Candle-Intervall

| Basket | Candle (min) | Trades | Win Rate | Profit Factor | Ø Haltedauer (h) |
|---|---|---|---|---|---|
| Basket 1 | 5 | 268 | 65.67% | 1.352 | 15.5 |
| Basket 1 | 10 | 452 | 70.13% | 1.250 | 9.4 |
| Basket 2 | 5 | 170 | 61.18% | 1.314 | 22.3 |
| Basket 2 | 10 | 264 | 65.15% | 1.235 | 16.7 |
| Basket 2 | 15 | 233 | 62.66% | 1.178 | 18.7 |
| Basket 2 | 30 | 253 | 65.22% | 0.971 | 17.4 |
| Basket 2 | 60 | 311 | 63.99% | 1.025 | 13.9 |
| Basket 2 | 240 | 222 | 57.21% | 0.720 | 18.0 |
| Basket 3 | 5 | 28 | 28.57% | 0.262 | 18.3 |
| Basket 3 | 10 | 46 | 47.83% | 0.374 | 12.9 |
| Basket 3 | 15 | 42 | 40.48% | 0.282 | 15.5 |
| Basket 3 | 30 | 41 | 53.66% | 0.250 | 14.3 |
| Basket 3 | 60 | 41 | 60.98% | 0.281 | 11.4 |
| Basket 3 | 240 | 52 | 44.23% | 0.365 | 14.5 |

Tabelle 5.5: Backtest-Ergebnisse 2/2 (kostenfrei): Trade-Statistiken je Basket und Candle-Intervall

Ohne Transaktionskosten und Slippage zeigt sich ein deutlich anderes Bild (Abbildung 5.5 bis 5.7): Basket 1 und weite Teile von Basket 2 erzielen positive Sharpe Ratios (bis 2.6 bei 5-Minuten-Kerzen), während Basket 3 auch kostenfrei durchgehend negativ bleibt.

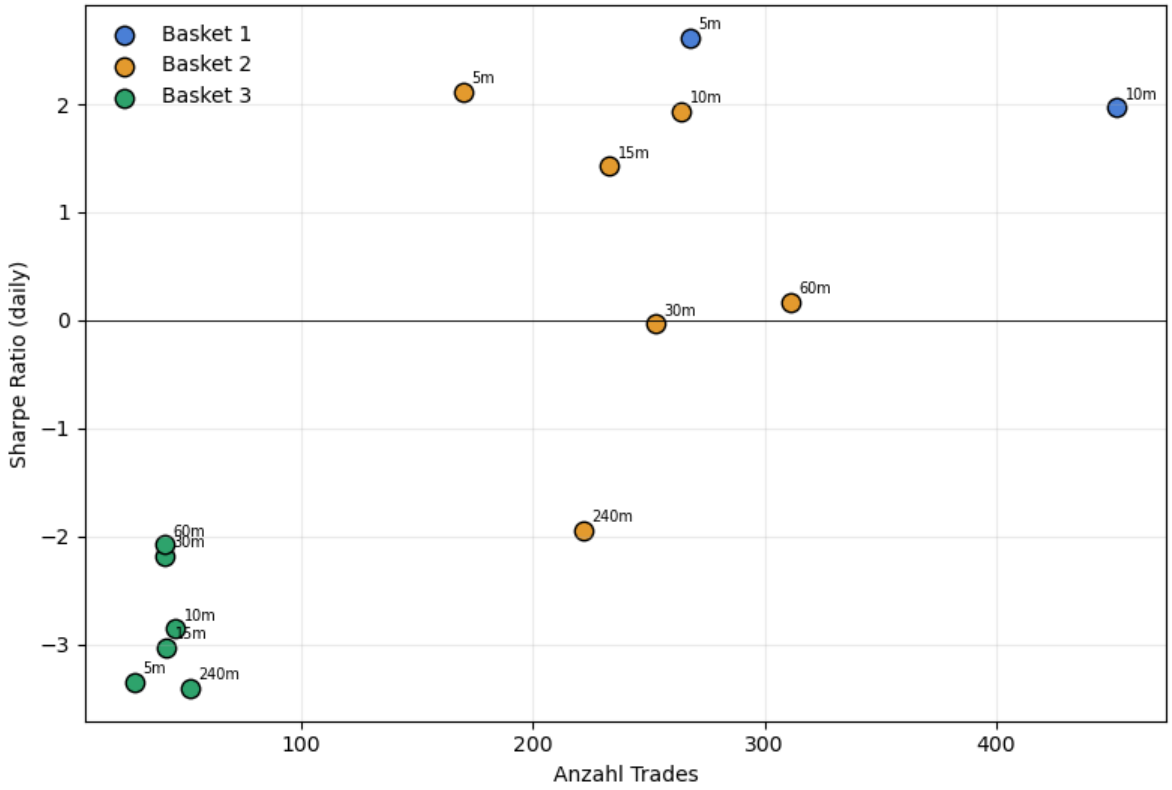



Abbildung 5.5: Trades vs. Sharpe Ratio je Basket/Kerzenlängen-Kombination, kostenfrei

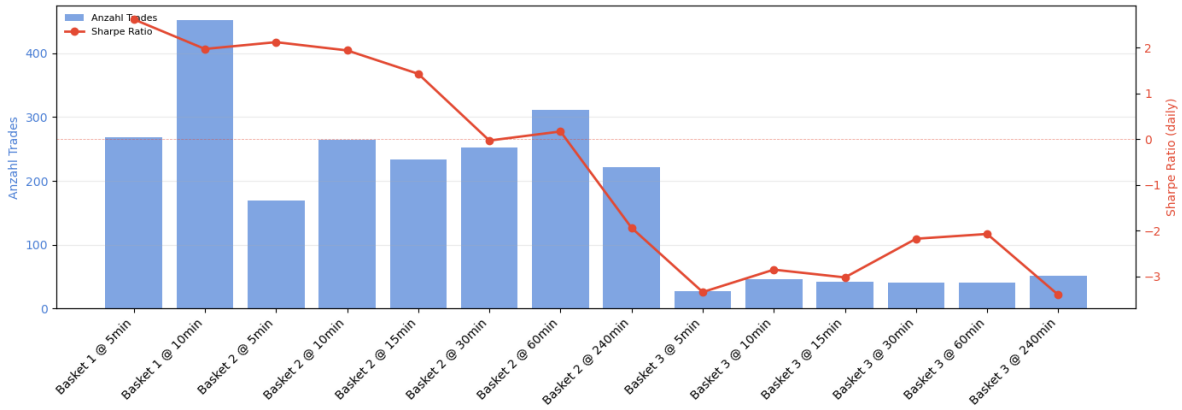



Abbildung 5.6: Trades und Sharpe Ratio je Basket/Kerzenlängen-Kombination im Vergleich, kostenfrei

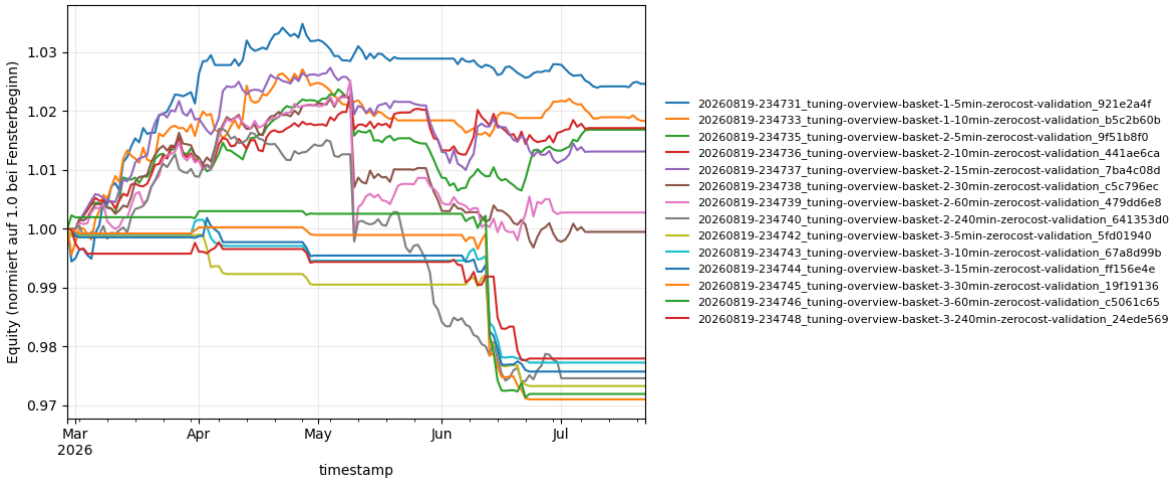



Abbildung 5.7: Normierte Equity-Kurven aller 14 Basket/Kerzenlängen-Kombinationen, kostenfrei

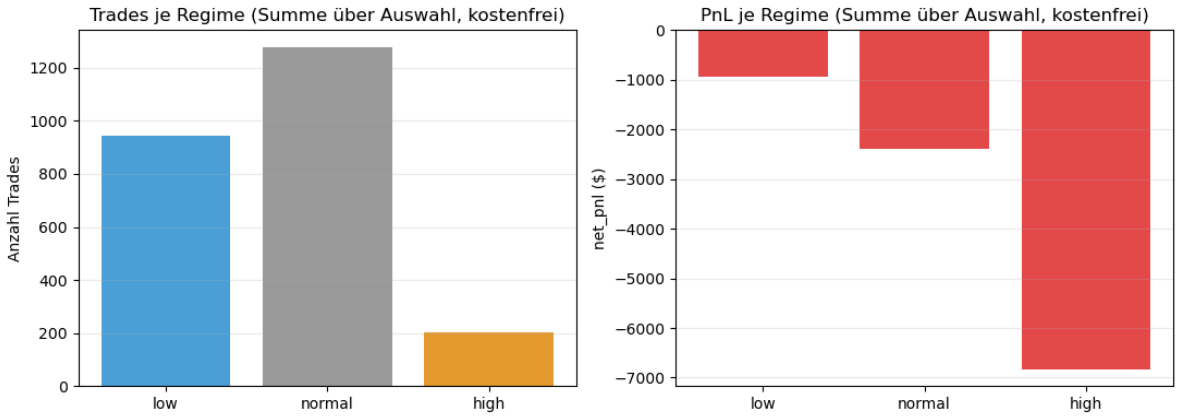



Abbildung 5.8: Trades und PnL pro Regime, Kostenfrei

## 5.2 Interpretation

Die grösste Erkenntnis liegt im Kontrast zwischen den kostenpflichtigen und den kostenfreien Backtests. Basket 1 und weite Teile von Basket 2 weisen vor Kosten eine klare positive Tendenz auf. Basket 1 (5 min) erzielt einen Sharpe von $2.616$ bei einer Win Rate von $65.67\,\%$ und einem Profit Factor von $1.352$, Basket 2 zeigt bei 5–15-Minuten-Kerzen ebenfalls durchgehend positive Sharpe Ratios ($1.4$ bis $2.1$). Nach Abzug von Handelsgebühren und Slippage können diese die Returns allerdings nicht im positiven Bereich halten. Die Strategie identifiziert in diesen Fällen tatsächlich mean-reversion-fähige Cluster mit einem realen statistischen Vorteil, der jedoch durch die hohe Trade-Frequenz von den Transaktionskosten vollständig nichtig gemacht wird. Basket 3 unterscheidet sich davon qualitativ. Hier bleiben Sharpe Ratio und Win Rate auch kostenfrei durchgehend negativ und die Trade-Anzahl liegt mit 28 bis 52 Trades je Kombination deutlich unter jener der anderen beiden Baskets. Das deutet darauf hin, dass die von der TDA-Clusterbildung in Basket 3 identifizierten Assetgruppen kein verwertbares Mean-Reversion-Verhalten aufweisen und dadurch weniger Handelssignale generieren. Dies deckt sich mit der Clusteranalyse aus Abschnitt 4.3.3: An 35,6 % der Tage liegt in Basket 3 kein Cluster über der Persistenzschwelle, noch extremer bei den Backtest-Daten zeigt sich dies (vgl. Abbildung 4.5). Die wenigen Signale, die entstehen, sind auch nicht von guter Qualität. Im Gegensatz zu Basket 1/2 handelt es sich hier nicht um ein reines Kostenproblem, sondern dass die Handelsstrategie nicht greift.

Es zeigt sich, dass die meisten Trades in Normal- oder Low-Volatility-Regimen stattfinden, während in High-Volatility-Regimen nur wenige Trades ausgelöst werden. Dieses Bild zeigt sich sowohl mit Handelskosten (Abbildung 5.4) als auch kostenfrei (Abbildung 5.8). Die Verluste in High-Volatility-Regimen liegen dabei in beiden Varianten in einem ähnlichen Bereich, während die beiden anderen Regime deutlich geringere Verluste aufweisen. Dies lässt sich zum einen auf die geringere Anzahl Trades zurückführen, zum anderen auf die kleinere Positionsgrösse pro Trade in diesem Regime, wodurch die Handelskosten dort weniger stark ins Gewicht fallen.

# Kapitel 6

# Fazit und Ausblick

## 6.1 Fazit

Um zu prüfen, ob die Strategie unabhängig von Transaktionskosten und Slippage grundsätzlich Rendite generiert, wurden diese Kosten zunächst auf null gesetzt. Dadurch lässt sich die Performance der Strategie isoliert betrachten. In diesem Szenario zeigt die Strategie im Basket 1 eine positive Rendite. Sobald jedoch realistische Transaktionskosten und Slippage berücksichtigt werden, wird die Performance negativ.
Die Strategie kann also grundsätzlich eine positive Rendite erzeugen, wird aber durch die anfallenden Kosten unprofitabel. Für Kapital in der Grössenordnung von Privatanlegern wäre sie unter den aktuellen Kostenbedingungen daher nicht profitabel. Eine Umsetzung wäre insbesondere bei institutionellen Investoren denkbar, die aufgrund höherer Handelsvolumina und entsprechender Vereinbarungen deutlich tiefere Transaktionskosten erhalten können, beispielsweise durch Mengenrabatte, niedrigere Brokerkommissionen oder günstigere Börsen- und Ausführungsgebühren.
Der topologische Ansatz zeigt Potential. Bei den Liquiditätsbaskets mit stetig vorhandenen Clustern konnten erfolgreich Paare gefunden werden, womit er als Clustering-Algorithmus für diverse Pair-Trading-Strategien dienen kann. Die Cluster sind jedoch meist Ketten und liefern keine schönen internen Strukturen mit denen Subcluster gebildet werden könnten. Es wird vermutet, dass dies an der hohen Marktabhängigkeit von Bitcoin und Ethereum liegt.

## 6.2 Ausblick

### 6.2.1 Multi-Asset-Ansatz nach Lin et al.

Lin et al. (2021) schlagen einen Rahmen vor, der über paarweises Trading hinausgeht: Die EWMA-/GARCH-normierte Renditedifferenz mehrerer Assets wird innerhalb eines Clusters zu einer Grösse $X_{\max}$ aggregiert, ein nichtparametrisches Wilks-Toleranzintervall dient als Entry-Schwelle. Aus Zeitgründen und auf Empfehlung des Betreuers wurde dieser Ansatz nicht weiter verfolgt, da die backtest Resultate unbrauchbar waren. Umgesetzt und im Backtest verwendet wird ausschliesslich die paarweise Bollinger-Band/Z-Score-Strategie aus Abschnitt 3.4. Eine Erweiterung auf den vollen Cluster-Rahmen nach Lin et al. bleibt damit ein möglicher nächster Schritt.

### 6.2.2 Kalman-Filter für dynamische Spread-Schätzung

Das Konzept des Kalman-Filters als dynamische Alternative zur rollierenden OLS-Hedge-Ratio-/Bollinger-Schätzung ist in Abschnitt 2.2.2 eingeführt. Auch dieser Ansatz wurde aus Zeitgründen und auf Empfehlung des Betreuers nicht implementiert. Ein nächster Schritt wäre der Ersatz der rollierenden OLS-Schätzung

durch einen Kalman-Filter, der sich laufend an neue Beobachtungen anpasst und dadurch schneller auf Regimewechsel reagieren könnte, ohne die Lag-Problematik fester Fenstergrössen aus Abschnitt 3.4.

### 6.2.3 Andere Assetklassen

Die Verwendung anderer Assetklassen könnte schönere topologische Strukturen hervorbringen. Es wäre interessant zu sehen, ob sich auch Anlageklassen wie Aktien und Kryptowährungen in Kombination ebenfalls erfolgreiche Cluster bilden.

# Literaturverzeichnis


Binance (2026). Trading fee schedule. `https://www.binance.com/en/fee/schedule`. besucht am 20.08.2026.

Chan, E. P. (2013). *Algorithmic Trading: Winning Strategies and Their Rationale*. Wiley Trading. Wiley, 1st edition.

Goel, A., Pasricha, P., and Mehra, A. (2020). Topological data analysis in investment decisions. *Expert Systems With Applications*, 147:113222.

Guritanu, E., Barbierato, E., and Gatti, A. (2025). Topological machine learning for financial crisis detection: Early warning signals from persistent homology. *Computers*, 14(10):408.

Lin, T.-Y., Chen, C. W. S., and Syu, F.-Y. (2021). Multi-asset pair-trading strategy: A statistical learning approach. *North American Journal of Economics and Finance*, 55:101295.

Majumdar, S. and Laha, A. K. (2020). Clustering and classification of time series using topological data analysis with applications to finance. *Expert Systems With Applications*, 162:113868.

Rudkin, S., Rudkin, W., and Dłotko, P. (2023). On the topology of cryptocurrency markets. *International Review of Financial Analysis*, 89:102759.

Woo, S. J. (2025). Fachmodul hs 2025/2026. Aufgabenstellung/interne Unterlagen, Ostschweizer Fachhochschule (OST).

Woo, S. J. (2026a). Additional information for bachelor thesis. Unveröffentlichte Unterlagen des Referenten der Bachelorarbeit, Ostschweizer Fachhochschule (OST).

Woo, S. J. (2026b). Suggested methods for improving trading performance. Unveröffentlichte Unterlagen des Referenten der Bachelorarbeit, Ostschweizer Fachhochschule (OST).

Woo, S. J. (2026c). Topological data analysis for multi-asset crypto mean-reversion trading. Unveröffentlichte Unterlagen des Referenten der Bachelorarbeit, Ostschweizer Fachhochschule (OST).

Zia, A., Khamis, A., Nichols, J., Tayab, U. B., Hayder, Z., Rolland, V., Stone, E., and Petersson, L. (2024). Topological deep learning: a review of an emerging paradigm. *Artificial Intelligence Review*, 57:77.

# Hilfsmittelverzeichnis

Dieses Verzeichnis listet die im Rahmen dieser Arbeit eingesetzten Hilfsmittel auf, die keine wissenschaftliche Literatur darstellen: KI-gestützte Werkzeuge sowie die verwendeten Datenquellen und Programmierschnittstellen.

Im Rahmen dieser Arbeit wurden KI-gestützte Werkzeuge wie folgt eingesetzt:

| **KI-Tool (Version)** | **Zweck / Phase** | **Betroffene Teile** |
|---|---|---|
| Claude (Claude.ai, Sonnet) | Sprachliche Überarbeitung und Formulierung von Fliesstext, Strukturierung und Gliederung der Kapitel, Ergänzung von Gleichungen und Zitaten, LaTeX-Formatierung | Kap. 1–6 (Fliesstext), Literaturverzeichnis |
| Claude Code | Diagnose, Debugging und Generierung von Codeabschnitten der Python-Codebasis, Identifikation methodischer Implementierungsfehler | Codebasis |

Tabelle 6.1: Übersicht über den Einsatz von KI-Tools in dieser Arbeit

Sämtliche von KI-Tools vorgeschlagenen Inhalte wurden von den Autoren geprüft, fachlich verifiziert und bei Bedarf angepasst. Die inhaltliche und methodische Verantwortung für die Arbeit liegt vollständig bei den Autoren.

Zusätzlich zur wissenschaftlichen Literatur (Literaturverzeichnis) wurden folgende externe Datenquellen und Programmierschnittstellen verwendet:

| Quelle | Verwendungszweck | Betroffene Teile |
|---|---|---|
| CoinGecko API<br>`https://docs.coingecko.com/reference/introduction`<br>(besucht am 20.08.2026) | Bestimmung des Kandidatenpools (Top-100 nach Marktkapitalisierung) sowie historische Tageswerte (Marktkapitalisierung, Volumen, Preis) für die Filterkette | Abschnitt 4.1.1, 4.1 |
| Binance API<br>`https://developers.binance.com/docs/binance-spot-api-docs/rest-api`<br>(besucht am 20.08.2026) | Abfrage der 5-Minuten-OHLCV-Zeitreihen für das finale Asset-Universum | Abschnitt 4.1.2 |
| CoinMarketCap Spot Exchange Rankings<br>`https://coinmarketcap.com/rankings/exchanges/`<br>(besucht am 23.07.2026) | Bestimmung der 20 grössten Handelsplätze für Filter 3 (Exchange-Abdeckung) | Abschnitt 4.1.1 |

Tabelle 6.2: Übersicht über die verwendeten Datenquellen und Programmierschnittstellen

# Eigenständigkeitserklärung für schriftliche Arbeiten

**Mit unserer untenstehenden Unterschrift bestätigen wir, dass wir…**

- die vorliegende Arbeit ohne fremde Hilfe und ohne Benützung anderer als der angegebenen Hilfsmittel verfasst haben.
- die Verwendung von KI-Tools und die von KI erzeugten Texte und Bilder entsprechend den Vorgaben deklariert haben.[1]
- zur Kenntnis nehmen, dass die Arbeit mit elektronischen Hilfsmitteln auf Plagiate überprüft wird.[2]

**Titel der Arbeit:** Topological Data Analysis for Crypto Mean-Reversion Trading

**Verfasser*innen der Arbeit:** Amato Ilija, Mikus Ryan

**Ort, Datum:** Buchs 21.08.2026

**Unterschrift Amato Ilija:** _____

**Unterschrift Mikus Ryan:** _____

**Einverständniserklärung**

Wir sind damit einverstanden, dass unsere Arbeit bei einer Bewertung mit der Note 5.0 oder höher als exemplarische Arbeit im Modul genutzt werden darf. Für Bachelorarbeiten gilt zusätzlich: Bei einer Bewertung mit der Note 5.5 oder höher darf die Arbeit veröffentlicht werden.

☐ **ja** ☐ **nein**

**Ort, Datum:** Buchs 21.08.2026

**Unterschrift Amato Ilija:** _____

**Unterschrift Mikus Ryan:** _____

*Herbst 2025 – Letzte Überarbeitung: September 2025 – Fachteam Lehr- und Lernformen*

[1] Gemäss Dokument ≪Umgang mit KI bei schriftlichen Arbeiten≫

[2] Gemäss Dokument ≪Umgang mit Plagiaten im Departement Soziale Arbeit≫